ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Введение в машинное обучение

Задачи, модели и проверка результатов на текстовых данных

Цифровая лингвистика и локализация
Учебные примеры связаны с корпусом и лабораторными работами курса.

Задачи курса

Машинное обучение помогает распределять тексты по категориям, находить похожие сегменты, оценивать перевод и порождать новые тексты.

Для каждой задачи нужно определить входные данные, ожидаемый результат и способ проверки.

В лабораторных один корпус используется на разных этапах локализации. Так легче увидеть, как выбор метода связан с задачей.

Машинное обучение: определение

Машинное обучение — методы построения моделей, параметры которых определяют по данным. Модель использует найденные закономерности, чтобы получать ответы для новых объектов.

При обучении с учителем примеры содержат и описание объекта, и правильный ответ. Например: текст сегмента и метку «интерфейс».

Качество проверяют на примерах, которые не участвовали в обучении. Успех на знакомых данных ещё не показывает, как модель будет работать на новых.

Правила и обучаемая модель

Правило. Сравнить наборы подстановочных полей в исходной строке и переводе. Несовпадение даёт повод проверить сегмент.

Правило задаёт специалист. Его условия можно прочитать и изменить.

Модель. Определить тип контента по размеченным примерам.

Зависимость между признаками и ответом определяется при обучении. Насколько её можно объяснить, зависит от модели.

В проекте можно сочетать оба подхода: модель предлагает перевод, правила проверяют сохранность чисел и подстановочных полей.

Объект, признак и целевая переменная

Понятие	Определение	В нашем корпусе
Объект	Единица наблюдения	Один сегмент локализации
Признак	Измеряемая характеристика объекта	Длина и частоты слов
Целевая переменная	Ответ, который нужно предсказать	Тип контента
Набор данных	Совокупность наблюдений	160 сегментов, 4 типа

Обучение, проверка и применение

При обучении алгоритм подбирает параметры модели по обучающей выборке. Проверочная выборка помогает выбирать настройки. Тестовая выборка нужна для итоговой оценки.

При применении обученная модель получает новый объект и возвращает предсказание. Правильный ответ в этот момент обычно неизвестен.

Если многократно подбирать настройки по тестовой выборке, она начинает выполнять роль проверочной. Итоговую оценку тогда нужно получать на новых данных.

Основные постановки задач

Задача	Что требуется получить	Пример
Классификация	Метка из заданного набора	Тип контента
Регрессия	Числовое значение	Длина перевода
Кластеризация	Группы похожих объектов	Обзор незнакомого корпуса
Поиск	Упорядоченный список кандидатов	Подсказки из памяти переводов
Генерация	Новую последовательность	Продолжение текста

Классификация

Классификация — предсказание метки из заранее заданного набора классов по признакам объекта.

В Л.р. № 1 классы: интерфейс, документация, маркетинг и юридические тексты. Классификатор получает русский эталонный перевод и предсказывает его тип.

Категории должны различаться по понятным правилам. Неоднозначные случаи сначала разбирают в инструкции по разметке.

Дерево решений



Во внутренних узлах дерево проверяет признаки. В листьях находятся ответы. Последовательность проверок можно проследить для отдельного сегмента.

Понятная структура облегчает разбор решений, но не гарантирует высокой точности. Глубокое дерево может запомнить обучающие примеры.

Точность классификации

Доля правильных ответов, или accuracy:

$$\text{accuracy} = \frac{\text{число верных ответов}}{\text{число объектов}}$$

На сбалансированном корпусе из четырёх классов постоянный ответ одним классом даёт 0,25. Это базовый уровень для сравнения.

На несбалансированных данных высокая accuracy может скрывать плохое качество для редкого класса. Поэтому рассматривают и матрицу ошибок.

Матрица ошибок



Матрица показывает, какие истинные классы модель путает. Подписи осей определяют, где расположены правильные метки и предсказания.

Разбирая ошибку, нужно прочитать сам сегмент: длина, синтаксис и терминология помогают объяснить смешение типов.

Кросс-валидация

При пятикратной кросс-валидации данные делят на пять частей. Модель пять раз обучают на четырёх частях и проверяют на оставшейся. Каждый объект один раз оказывается контрольным.

Сравнивают среднее качество и разброс результатов. Для классов сохраняют близкое соотношение меток в частях.

Векторизатор обучают внутри каждого разбиения. Близкие дубликаты и сегменты одного документа при необходимости объединяют в группы.

Переобучение

Переобучение возникает, когда модель слишком хорошо подстраивается под особенности обучающих примеров и хуже работает на новых.

Пример из Л.р. № 1: доля верных ответов на обучающих данных — 1,000, средняя при кросс-валидации — 0,744.

Разрыв требует проверки: причины могут быть связаны со сложностью модели, малым объёмом данных, утечкой или различиями между выборками.

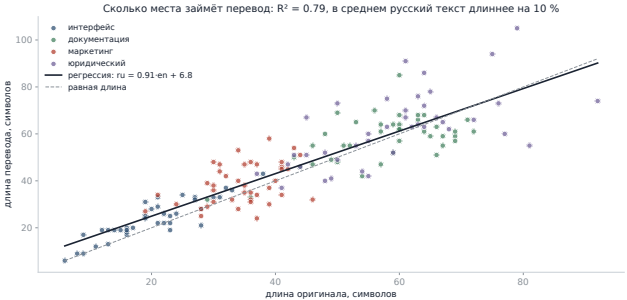
Регрессия

Регрессия — предсказание числовой целевой переменной по признакам объекта. В локализации можно оценивать длину перевода по длине оригинала.

$$\widehat{y} = ax + b$$

x — длина оригинала, $\widehat{y}$ — прогноз длины перевода, a и b — параметры, найденные по данным.

Длина оригинала и перевода



Каждая точка соответствует паре сегментов. Прямая описывает общую зависимость, отклонения от неё показывают ошибки прогноза.

На учебном корпусе R^2 около 0,79. Это характеристика данного опыта, которую нужно перепроверять на новом проекте.

Как понимать коэффициент детерминации

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

R^2 сравнивает сумму квадратов ошибок модели с прогнозом постоянным средним. Единица соответствует точным прогнозам, ноль — ошибке на уровне среднего; возможны отрицательные значения.

Помимо R^2, полезна средняя абсолютная ошибка в символах. Она прямо показывает, насколько прогноз неточен для интерфейса.

Среднее расширение и ограничения интерфейса

На корпусе перевод в среднем длиннее оригинала примерно на 10 %, а для интерфейсных строк — примерно на 20 %.

Единый коэффициент для всего корпуса может недооценивать длину кнопок и сообщений. Прогноз нужно проверять по типам контента.

Видимая ширина строки зависит также от шрифта и размера поля. Длина в символах служит приближением.

Кластеризация

Кластеризация объединяет объекты в группы по выбранным признакам и критерию сходства. Готовые метки классов для обучения не требуются.

Количество кластеров может задаваться заранее, как в k-средних, или определяться условиями алгоритма. Для сравнения текстов можно использовать эмбеддинги — векторы, полученные обученной моделью.

Кластеры могут отражать длину, тематику или тип оформления. Совпадение с редакционными категориями нужно проверять отдельно.

Кластеры и типы контента



Разные цвета показывают разметку и результат кластеризации. Проекция помогает рассмотреть группы, но не сохраняет все расстояния исходного пространства.

На готовых эмбеддингах ARI около 0,17: найденные группы слабо совпадают с четырьмя типами контента.

Оценка совпадения разбиений: ARI

Скорректированный индекс Рэнда (ARI) сравнивает пары объектов: вместе ли они находятся в обоих разбиениях. Поправка учитывает совпадение, ожидаемое случайно.

ARI = 1 означает одинаковые разбиения. Ожидаемое значение для случайных независимых разбиений близко к 0; возможны отрицательные значения.

Низкий ARI показывает слабое совпадение с выбранной разметкой. Он сам по себе не объясняет, какие свойства объединили сегменты.

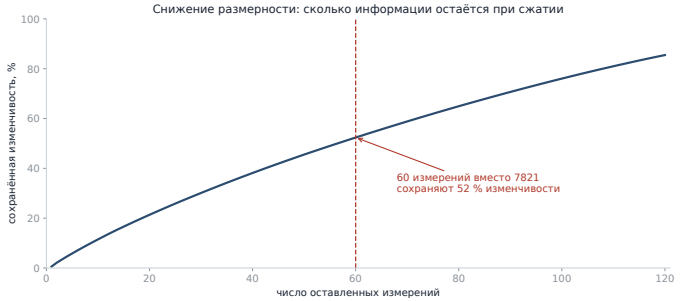
Снижение размерности

Снижение размерности заменяет исходные признаки меньшим числом координат, сохраняя часть структуры данных.

Для разреженных текстовых матриц используется усечённое сингулярное разложение (SVD). Так получают представление LSA — латентно-семантического анализа.

Двумерная проекция удобна для рисунка. Пространство для поиска обычно имеет больше двух измерений.

SVD: компактное представление



Матрица «сегменты × признаки» заменяется приближением меньшего ранга. В лабораторной используются 60 компонент.

На корпусе сохраняется около 52 % вариации признаков. Этот процент не является долей сохранённого смысла.

Ассоциации и кандидаты в термины

Ассоциативные меры показывают, какие единицы встречаются совместно чаще ожидаемого. Их используют для поиска устойчивых сочетаний.

$$\mathrm{PMI}(x, y) = \log \frac{P(x, y)}{P(x)P(y)}$$

Высокий PMI у редкой пары может быть случайностью. Кандидатов проверяют по частоте, контекстам и терминологической значимости.

Частота и устойчивость сочетания



Частотный список и список по PMI отвечают на разные вопросы. Частое сочетание может быть служебным, а редкое — случайным.

Глоссарий составляет специалист: статистика предлагает кандидатов, которые нужно проверить в контексте.

Ансамбли моделей

Ансамбль объединяет предсказания нескольких моделей. В классификации используют, например, голосование или усреднение вероятностей.

Случайный лес обучает несколько деревьев; бустинг последовательно добавляет модели, чтобы уменьшить ошибки ансамбля.

Совместное применение BLEU, правил и редакторской проверки — система контроля качества. Называть её ансамблем обучаемых моделей было бы неточно.

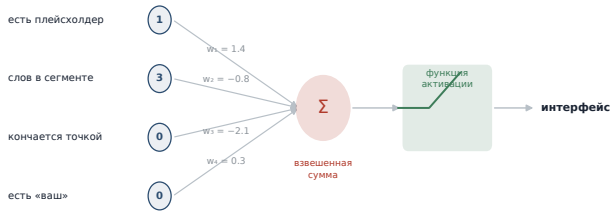
Искусственная нейронная сеть

Нейронная сеть — параметрическая модель, в которой преобразования входных признаков соединены в последовательность слоёв. Параметры подбираются при обучении.

$$\mathbf{h} = \varphi(W\mathbf{x} + \mathbf{b})$$

Название связано с исторической аналогией с нейроном. Оно не означает, что модель воспроизводит устройство мозга.

Нейрон: сумма и функция активации



Обучение — это подбор весов w по размеченным примерам. Признаки здесь названы по-человечески; в реальной модели их тысячи и имён у них нет.

Признаки умножаются на веса, результаты складываются со смещением. Функция активации преобразует полученную сумму.

Нелинейные активации позволяют сети описывать зависимости, недоступные одной линейной модели.

Свёрточные и рекуррентные сети

Свёрточная сеть применяет общие фильтры к локальным фрагментам входа. Для текста фильтр может обнаруживать характерные сочетания соседних символов или слов.

Рекуррентная сеть последовательно обновляет скрытое состояние, используя текущий элемент и состояние предыдущего шага.

В Л.р. № 4 используется GRU — разновидность рекуррентной сети. Её внутреннее состояние позволяет учитывать предшествующий текст.

Обучение с подкреплением

При обучении с подкреплением агент выбирает действия, получает обратную связь в виде награды и учится повышать суммарную награду.

Эта постановка отличается от классификации по готовым меткам. В курсе она нужна для общей картины; отдельной лабораторной по ней нет.

Выбор метода для задачи локализации

Задача	Подход	Практика
Определить тип текста	Классификация	Л.р. № 1
Найти похожий сегмент	Поиск по строкам и векторам	Л.р. № 2
Оценить перевод	Метрики, правила, ручной анализ	Л.р. № 3
Продолжить текст	Языковая модель	Л.р. № 4

Вопросы для самопроверки

Почему высокая точность на обучающей выборке не гарантирует качество на новых данных?

Чем кластеры отличаются от заранее заданных классов?

Какие ошибки прогноза длины перевода важнее всего для интерфейса?

В ответах укажите данные, критерий оценки и ограничения выбранного метода.

→ **основные задачи машинного обучения** — параметры и результаты можно сравнить на примерах корпуса.

Источники и данные

Документация scikit-learn: классификация, регрессия, кластеризация и оценка качества.

Jurafsky, Martin. Speech and Language Processing: текстовые признаки и языковые модели.

Численные примеры и рисунки: корпус курса, лабораторные и скрипты в папке tex. Значения относятся к указанным учебным опытам.