

ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Введение в машинное обучение

Основные задачи и технологии интеллектуальной обработки данных

Версия для направления «Цифровая лингвистика и локализация».
Все примеры и все числа на слайдах посчитаны на учебном корпусе курса:
160 сегментов локализации, четыре типа контента.

Где эта лекция в курсе

Материал собран из трёх презентаций, и они не повторяют друг друга.

1. Введение в МО

Эта лекция. Общая карта: какие бывают задачи и чем они отличаются друг от друга.

2. Интеллектуальный анализ текстовых данных

Работа с корпусом: сбор, форматы, выбросы, устройство нейрона, GPT и трансформер.

3. Текст как данные

То, на что опираются лабораторные: векторизация, метрики качества текста, разметка.

Зачем это знать лингвисту. Вы не будете обучать модели. Вы будете решать, годится ли результат модели для проекта, и объяснять заказчику, почему он стоит столько, сколько стоит. Для этого нужно понимать, что модель в принципе умеет, а чего не умеет никогда.

Машинное обучение

англ. machine learning, ML

Класс методов искусственного интеллекта, характерная черта которых — **не прямое решение задачи, а обучение на примерах.**

Программа по правилам

Лингвист пишет: «кончается
вопросительным знаком и короче пяти
слов — значит интерфейс». Правила
видны и правятся, но каждое написано
руками.

Машинное обучение

Лингвист размечает 160 сегментов по
типам. Правила машина выводит сама.
Написать их она не может — только
применить.

Оба подхода в курсе встретятся, и мы их сравним численно: в Л.р. № 3 формальные проверки написаны по правилам, а модель перевода обучена на примерах.

Что нужно, чтобы машинное обучение состоялось

Данные

Размеченные примеры.
В нашем корпусе — 160 сегментов, у каждого проставлен тип контента.

Это делает лингвист, и это самая дорогая часть.

Признаки

Числа, которыми описан текст. Слова, буквосочетания, длина, наличие плейсхолдера.

Здесь решается почти всё — увидим в Л.р. № 1.

Алгоритм

Способ связать признаки с ответом. Наивный Байес, дерево решений, логистическая регрессия.

Меняется одной строкой кода.

Заранее о главном выводе первой лабораторной. Смена алгоритма на том же корпусе дала прирост точности **0,01**. Смена признаков — **0,21**. Порядок величин разный, и это определяет, на что тратить время в проекте.

Машинное обучение и искусственный интеллект

Искусственный интеллект — широкая область: всё, что заставляет машину вести себя разумно, включая системы правил, планировщики, экспертные системы.

Машинное обучение — её часть: методы, которые извлекают закономерность из данных.

Глубокое обучение — часть машинного обучения: многослойные нейронные сети.

Почему это важно проговорить. Системы автоматического перевода прошли все три стадии: правила (до 1990-х), статистика (1990–2015), нейросети (с 2015). В отрасли до сих пор работают инструменты всех трёх поколений, и вы будете иметь дело с каждым.

Четыре направления машинного обучения

Классическое обучение

классификация
регрессия
кластеризация
снижение размерности

**Л.р. № 1 и № 2
весь курс здесь**

Ансамбли

несколько моделей
исправляют ошибки
друг друга

**Л.р. № 3:
три проверки**

Нейросети и глубокое обучение

перцептрон
рекуррентные сети
трансформеры

**Л.р. № 4,
машинный перевод**

Обучение с подкреплением

действие в среде
и отклик на него

*в локализации
не применяется*

*Первые три направления в курсе используются.
Четвёртое названо и оставлено в стороне: переводческий проект —
не среда, в которой можно действовать и получать отклик.*

Классификация

обучение с учителем

Задача: отнести объект к одному из заранее известных классов. Классы задаёт человек, машина учится их различать по размеченным примерам.

Наша задача в Л.р. № 1: по тексту сегмента определить тип контента — интерфейс, документация, маркетинг или юридический текст.

Зачем это нужно в проекте. Перед началом работы приходит выгрузка на десятки тысяч строк без разделения. От типа контента зависит всё: кто переводит, по какому глоссарию, с каким тоном, какая ставка. Разбирать руками — это дни работы.

Классы у нас равные — по 40 сегментов. Решение, всегда отвечающее самым частым классом, даёт **0,25**. Всё, что ниже этого, бесполезно, какой бы сложности ни была модель.

Наивный Байес: с чего начинались спам-фильтры

Машина считает, **сколько раз слово встретилось** в письме, и по этим счётчикам оценивает вероятность того, что письмо — спам.


Число вхождений слова: сколько раз слово встретилось в этом тексте

«Не удалось сохранить файл»	0	1	1	0	1	1
«Файл сохранён»	0	0	0	1	0	1
«Сохранить файл как...»	1	0	1	0	0	1
	как	не	сохранить	сохранён	удалось	файл

«сохранить» и «сохранён» — два разных столбца: машина не знает, что это формы одного слова

Это представление называется **мешком слов**. Порядок слов теряется полностью: «не удалось подключиться» и «удалось не подключиться» дают одинаковый вектор. Для типа контента терпимо, для оценки перевода — уже нет, и в Л.р. № 3 это станет принципиальным.

Тот же алгоритм на нашем корпусе



Матрица ошибок показывает не только сколько ошибок, но и *какие*: какой класс с каким смешивается.


Диагональ — верные ответы. Всё вне её — то, что в проекте придётся переделывать руками.

Читается по-лингвистически: путаются документация, маркетинг и юридический текст — все трое состоят из полных предложений. Интерфейс не путается почти ни с чем: короткие безглагольные строки ни на что не похожи.

→ **векторизация текста** — та же матрица, но признаки переключаются на ходу.

Дерево решений: правила, которые можно прочесть

Дерево решений на шести признаках, придуманных лингвистом: точность 0.631
(символьные n-граммы на том же корпусе — 0.744, но их правила прочесть нельзя)



Шесть признаков придуманы лингвистом: длина, финальная точка, начальный инфинитив, плейсхолдер, обращение «вы», юридические маркеры.

Что мы узнали из дерева

Хорошая новость

Машина сама вывела правила, под которыми подписался бы редактор: интерфейс не кончается точкой; юридический текст выдают «настоящий» и «стороны»; документация длиннее маркетинга.

Такую модель можно показать заказчику и защитить.

В общей версии курса здесь пример про оценку кредитоспособности заёмщика. Механика та же и вывод тот же: вопросы дерева бывают адекватны человеку, а бывают нет — работать может и то и другое.

Плохая новость

Точность **0,631**. Непрозрачная модель на символьных n-граммах даёт **0,744** — и объяснить её решения нельзя.

Выбор между понятностью и точностью — не техническая мелочь, а условие договора: за понятную модель платят, когда решение нужно обосновывать.

Регрессия

обучение с учителем

Задача та же — предсказать ответ по признакам, но ответ **число**, а не класс.


Настоящая задача локализации: сколько места займёт перевод?

От этого зависит вёрстка интерфейса (текст должен влезть в кнопку), объём работ и цена проекта. Отраслевое правило «русский длиннее английского процентов на пятнадцать» — это и есть коэффициент регрессии, только посчитанный кем-то однажды и переписываемый из презентации в презентацию.

Посчитаем его сами на своём корпусе — и посмотрим, насколько ему можно верить.

→ **три задачи лекции** — задайте свой запас под перевод и проверьте свою строку.

Сколько места займёт перевод



На нашем корпусе русский текст длиннее английского в среднем на **10 %**, а не на пятнадцать. И разброс по типам контента больше самой поправки: интерфейс **+20 %**, документация **+2 %**. Средний коэффициент, применённый ко всему проекту сразу, ошибается ровно там, где цена ошибки максимальна — на кнопках.

Кластеризация

обучение без учителя

Разбиение множества объектов на группы, **заданные не человеком, а данными**. Разметки нет: машина сама решает, что на что похоже.

Как это выглядит в работе: пришёл незнакомый корпус на 30 тысяч сегментов. Хочется разложить его на группы, чтобы оценить объём и назначить исполнителей до начала перевода.

Предупреждение, которое лучше сделать заранее. В Л.р. № 2 кластеризация даст согласие с нашей разметкой около нуля. Это не сбой лабораторной и не ваша ошибка. Посмотрим, почему.

Что кластеризация находит на самом деле

Кластеризация ищет группы, которые есть в данных, а не те, которые придумал человек



ARI — мера согласия двух разбиений: **1,0** — полное совпадение, **0,0** — как если бы группы нарезали случайно. Получилось **0,172**.

→ **память переводов** — ARI на трёх представлениях и разброс по восьми запускам.

Почему это правильный результат, а не поломка

Кластеризация честно нашла структуру, которая в данных есть. Просто это **не та структура**, которую придумал человек.

Машина сгруппировала сегменты по длине и доле служебной лексики — по тому, что сильнее всего различает тексты численно. Наши четыре типа контента различаются *назначением*, а оно из формы видно лишь отчасти.

Правило, которое стоит унести с собой. Кластеризация отвечает на вопрос «на какие группы эти данные распадаются сами». Она не отвечает на вопрос «разложи их по моим категориям» — для этого нужна разметка и классификация. Подбором числа кластеров заставить её воспроизвести разметку нельзя, и в Л.р. № 2 вы это проверите.

Снижение размерности

обучение без учителя, оно же обобщение


Преобразование, которое **уменьшает число признаков**, стараясь сохранить то, что в данных существенно.

Тексты описываются тысячами признаков, и почти все они нули: конкретное буквосочетание встречается в считанных сегментах. Сжатие собирает из множества слабых признаков несколько сильных.

Метод очень хорошо подходит для определения тематик текстов (*topic modelling*) — и это прямая опора Л.р. № 2, где TruncatedSVD и PCA применяются к нашему корпусу. Тот же приём лежит за «умными» подсказками в CAT-инструментах: подсказка ищется не по буквам, а по сжатому представлению смысла.

→ **память переводов** — один сегмент, четыре меры близости, и где они расходятся.

Сколько информации остаётся при сжатии



Сжатие в **130** раз сохраняет половину изменчивости корпуса. Вторая половина — это то, чем сегменты отличаются друг от друга по мелочам, и для поиска похожего она чаще мешает, чем помогает.

Поиск правил (ассоциации)

обучение без учителя

Метод ищет, что в данных встречается **вместе**.

Поиск правил на корпусе курса: какие слова ходят парами



Слева — ловушка, справа — инструмент. По частоте наверх всплывают служебные обороты. Мера силы связи (PMI) поднимает то, что действительно ходит парами: «программное обеспечение», «настоящие условия». Это заготовка глоссария, полученная за секунду, — её остаётся вычитать лингвисту.

Обучение с подкреплением

четвёртое направление — назовём и пойдём дальше

Модель не получает готовых ответов. Она **действует в среде** и получает отклик: награду или штраф. Так учат играть в го, водить автомобиль, управлять роботом.

Почему в нашем курсе этого не будет. Метод требует среды, в которой можно совершить действие и немедленно узнать, хорошим оно было или плохим. Перевод такой средой не является: оценку качества даёт человек, она приходит с задержкой в недели и стоит дороже самого перевода.

Знать о направлении стоит, применять его в локализации — нет.

Ансамбли

Несколько несовершенных моделей, **исправляющих ошибки друг друга**, работают лучше одной сильной.

Здесь работает бритва Оккама: задача должна решаться самым простым способом. Три простые модели, каждая из которых ошибается по-своему, обычно надёжнее одной сложной, которая ошибается вся сразу.

Технические схемы — стекинг, бэггинг, бустинг — различаются тем, как именно модели соединяют. Собирать их руками вам не придётся; важна сама идея.

А вот идея вам пригодится буквально. В Л.р. № 3 приёмка машинного перевода собрана ровно по этому принципу — из трёх разных средств, каждое из которых закрывает слепое пятно другого.

→ **метрики перевода** — сломать перевод и увидеть, что заметит каждое средство.

Ансамбль, собранный человеком



Три средства ловят разное и стоят разного. Метрика BLEU отправляет на проверку половину корпуса и при этом пропускает сегмент с разрушенным плейсхолдером {name} — его BLEU *выше* медианы. Формальная проверка находит этот сегмент мгновенно и стоит восьми регулярных выражений.

Нейронные сети


глубокое обучение

Математическая модель, построенная по принципу сети нервных клеток. Состоит из **нейронов** и связей между ними — **синапсов**.

Нейрон — это функция: принимает несколько чисел на вход, умножает каждое на свой вес, складывает и пропускает сумму через функцию активации. Вся сеть — это много таких функций, соединённых слоями.

Дальше — тот же пример, что был у дерева решений: определить тип сегмента. Так видно, чем нейрон отличается от правила, и почему «сеть научилась» — это всегда «подобрались числа».

Как устроен один нейрон



Обучение — это подбор весов w по размеченным примерам. Признаки здесь названы по-человечески; в реальной модели их тысячи и имён у них нет.

Здесь нет ничего, кроме арифметики. Признаки умножаются на веса, произведения складываются, сумма проходит через функцию активации. Веса **1,4, -0,8, -2,1, 0,3** никто не задавал — они подобраны по размеченным примерам. «Сеть научилась» всегда означает «подобрались числа».

Слои и обучение

Слои

Нейроны выстраивают в слои. Внутри слоя связей нет, между соседними — есть.

Смысл в том, что каждый следующий слой работает с признаками, которые предыдущий уже собрал, а не с исходным текстом.

Отсюда следует вещь, важная для приёмки. Сеть не знает правил и не может их назвать. Она не «понимает», что плейсхолдер {name} нельзя переводить, — она лишь редко видела обратное. Поэтому в Л.р. № 3 плейсхолдеры проверяются регуляркой, а не моделью.

→ **градиентный спуск** — «веса чуть двигают» — по шагам, с выбором шага и зерна.

Обучение

Обучить сеть — значит **расставить веса** так, чтобы на обучающих примерах ответы совпадали с размеченными.

Сеть отвечает, ошибку измеряют, веса чуть двигают туда, где ошибка меньше. Миллионы раз.

Свёрточные сети

зачем мы их пропускаем

Архитектура, заточенная под изображения: сеть ищет в картинке простые линии, из них собирает фигуры, из фигур — объекты.

В обработке текста их применяли, но они вытеснены трансформерами. Для локализации архитектура не нужна ни разу, а на разбор уходит четверть часа. Мы эти пятнадцать минут потратим на устройство языковой модели — во второй презентации курса.

Если встретите в вакансии «CNN» — это про компьютерное зрение, а не про вашу работу.

Рекуррентные сети

мост к Л.р. № 4

Сети, в которых связи образуют цикл: выход шага подаётся на вход следующего. Так сеть получает **память о том, что было раньше в последовательности**, — а текст и есть последовательность.

Именно на этой архитектуре работал машинный перевод примерно с 2014 по 2017 год, и именно её вы увидите в Л.р. № 4: сеть посимвольно порождает текст, обучившись на корпусе.

Посмотрите на её вывод внимательно. Он похож на язык, но рассыпается через несколько слов. Причина — у рекуррентной сети память короткая: к концу предложения начало уже размыто. Механизм внимания в трансформере придуман ровно против этого, и о нём — следующая презентация.

→ **языковая модель** — температура, top-k и top-p на символьной модели.

Итог: что где в курсе

Задача	Наш случай	Где отрабатываем
Классификация	тип контента по тексту сегмента	Л.р. № 1
Регрессия	длина перевода по длине оригинала	здесь, /intro/
Кластеризация	разложить незнакомый корпус	Л.р. № 2
Снижение размерности	поиск по памяти переводов	Л.р. № 2
Поиск правил	заготовка глоссария из корпуса	здесь, /intro/
Ансамбли	три средства приёмки перевода	Л.р. № 3
Нейронные сети	порождение текста, машинный перевод	Л.р. № 4

Обучения с подкреплением в таблице нет намеренно.

Где всё это можно потрогать руками

konkin-nikita.ru/gd_learn/

Шесть страниц на корпусе курса: те же числа, что в лабораторных.

Тема лекции	Что крутится	Страница
Дерево, регрессия, правила	признаки, запас под перевод, PMI	/intro/
Обучение сети	шаг, зерно, форма функции потерь	/
Классификация	слова против символьных n-грамм, стемминг	/vec/
Кластеризация, снижение размерности	четыре меры близости на одном запросе; ARI и разброс	/tm/
Ансамбли	сломать перевод и увидеть, что заметит каждое средство	/mt/
Рекуррентные сети	температура, top-k и top-p на символьной модели	/lm/

Что унести с этой лекции

1. **Модель без точки отсчёта — число без единиц измерения.** Прежде чем радоваться точности, посмотрите, сколько даёт решение, вообще не читающее текст. У нас это **0,25**.
2. **Признаки решают больше, чем алгоритм.** Смена модели — **+0,01**, смена способа превратить текст в числа — **+0,21**.
3. **Понятность и точность — разные вещи, и за них платят по-разному.** Дерево **0,631** и объяснимо, символьные n-граммы **0,744** и нет.
4. **Отрицательный результат — тоже результат.** Кластеризация не воспроизводит разметку, и это свойство метода, а не сбой.
5. **Средний коэффициент врёт там, где дороже всего.** Перевод длиннее на **10 %** в среднем и на **20 %** в интерфейсе — а место кончается именно на кнопках.