ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Интеллектуальный анализ текстовых данных

Подготовка корпуса, исследование зависимостей и нейросетевые представления

Цифровая лингвистика и локализация
Учебные примеры связаны с корпусом и лабораторными работами курса.

Содержание лекции

1. Подготовка корпуса: источник, структура, единица наблюдения. 2. Проверка качества: пропуски, дубликаты, необычные сегменты.

3. Исследование данных: признаки и зависимости. 4. Нейросетевые представления: нейрон, токенизация, внимание. 5. Проверка модели на задаче локализации.

Интеллектуальный анализ текстовых данных

Интеллектуальный анализ текстовых данных — поиск закономерностей в корпусе с помощью статистических и вычислительных методов.

Работа включает формулировку вопроса, подготовку данных, выбор представления, анализ и проверку интерпретации.

Сначала формулируют вопрос: например, какие сегменты потребуют ручной проверки. После этого выбирают признаки и метод.

Корпус и единица наблюдения

Корпус — организованная совокупность текстов с описанием происхождения и структуры. Единицей анализа может быть документ, предложение или сегмент локализации.

Сегмент локализации не всегда совпадает с предложением: кнопка, заголовок и сообщение об ошибке тоже могут быть отдельными сегментами.

Состав учебного корпуса

160 англо-русских сегментов: по 40 для интерфейса, документации, маркетинга и юридических текстов.

Для каждого сегмента хранятся идентификатор, тип, оригинал, эталонный и машинный перевод.

Учебный баланс классов задан специально. Он не описывает естественную долю типов в любом продукте.

Источники текстовых данных

Источник	Что может дать	Что нужно проверить
Материалы проекта	Строки продукта, глоссарий, память переводов	Версии и назначение строк
Параллельные корпуса	Пары оригиналов и переводов	Качество выравнивания
Размеченные корпуса	Морфология, синтаксис, категории	Совместимость схем разметки
Открытые коллекции	Тексты разных жанров	Происхождение и условия использования

Паспорт набора данных

Указать источник и период сбора, языки, объём, тематику и единицу разбиения. Описать поля, версии, схему разметки и известные ограничения.

Примеры должны показывать типичную строку, сложный случай и обнаруженную ошибку.

Для учебного корпуса описание находится в файле «О_данных.md». По нему проверяют, что именно представляют столбцы.

Форматы хранения

Формат	Для чего удобен	Типичная трудность
CSV / TSV	Таблицы сегментов и признаков	Кавычки, разделители, переносы строк
JSON / JSONL	Записи с полями и вложенной структурой	Согласованность структуры
TMX	Обмен памятью переводов	Теги и языковые варианты
XLIFF	Переводческие единицы и их состояние	Связь текста с технической разметкой

Кодировка и нормализация Unicode

Кодировка задаёт представление текста в байтах. Нормализация Unicode приводит эквивалентные последовательности символов к согласованной форме.

Внешне одинаковые имена файлов или буквы могут иметь разное кодовое представление. Это важно для поиска, сравнения и переносимости проекта.

Нормализация не должна незаметно менять различия, значимые для задачи: «все» и «всё», латинскую и кириллическую букву.

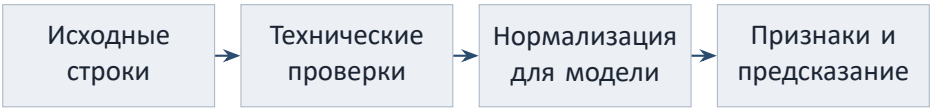
Пропуски, дубликаты и соответствие пар

Проверить пустые поля, повторяющиеся идентификаторы, точные и близкие дубликаты. Убедиться, что оригинал и перевод относятся к одному сегменту.

Дубликат может быть ошибкой выгрузки или необходимым повторением интерфейсной строки в разных контекстах.

Решение об удалении принимают после проверки контекста. Похожие строки не следует автоматически считать лишними.

Предобработка зависит от задачи



Проверку полей и тегов выполняют до удаления пунктуации. Для классификации могут потребоваться другие правила подготовки текста.

Исходный текст сохраняют рядом с подготовленным. Это позволяет восстановить причину ошибки и изменить обработку.

Обзор корпуса

Посчитать число сегментов по типам, языкам и источникам. Рассмотреть распределение длины, долю пустых строк, числа, теги и подстановочные поля.

Средние значения сопоставить с медианами и крайними наблюдениями. Прочитать примеры из каждой группы.

Необычный сегмент и ошибка

Аномалия — наблюдение, которое заметно отличается от остальных по выбранным признакам или модели. Оно может быть правильным редким случаем.

Длинная юридическая формулировка и повреждённое подстановочное поле необычны по разным причинам.

Список аномалий служит очередью для проверки. Автоматическое удаление может убрать редкий, но важный материал.

Расстояние до центра эмбеддингов

Эмбеддинг — плотный числовой вектор, полученный обученной моделью. Здесь рассматриваются готовые векторы сегментов.

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_i \mathbf{x}_i, \qquad d_i = \|\mathbf{x}_i - \bar{\mathbf{x}}\|_2$$

Можно отсортировать сегменты по расстоянию до среднего вектора. Перед этим нужно определить пространство, нормирование и меру расстояния.

В неоднородном корпусе единый центр может быть малоинформативен. Полезно сравнивать сегмент также с его типом или ближайшими соседями.

Почему аномалии требуют контекста

В прежнем опыте с эмбеддингами далеко от общего центра оказались юридические формулировки. Это может отражать редкий стиль, а не ошибку.

Чтобы проверить гипотезу, нужно прочитать сегменты, посмотреть их тип и сопоставить с соседями.

По одному расстоянию нельзя установить, нарушена ли грамматика, утеряно ли отрицание или испорчено ли поле.

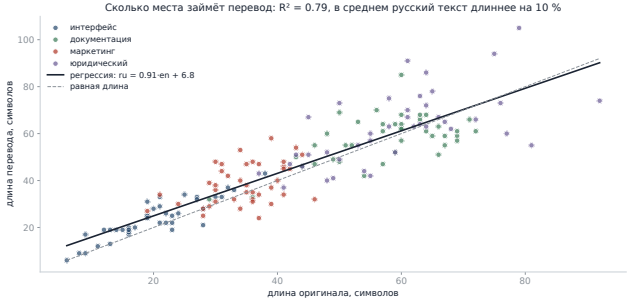
Числовые признаки текста

Длина в символах и словах, средняя длина слова, число предложений и доля цифр помогают описывать корпус.

TTR — отношение числа разных словоформ к общему числу словоупотреблений. На коротких текстах оно обычно выше, поэтому сравнение зависит от длины.

Показатель лексического разнообразия не следует интерпретировать без указания токенизации и длины текстов.

Диаграмма рассеяния



Каждая точка — сегмент: по горизонтали длина оригинала, по вертикали длина перевода. Рисунок помогает рассмотреть зависимость и необычные наблюдения.

График рассматривают до интерпретации коэффициентов: связь может быть нелинейной или различаться по группам.

Корреляция Пирсона

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}$$

Коэффициент измеряет линейную связь двух непостоянных признаков и лежит от −1 до 1. Знак показывает направление, модуль — силу линейной связи.

r = 0 означает отсутствие линейной корреляции; нелинейная зависимость при этом возможна. Корреляция не доказывает причинность.

Ранговая корреляция

Ранговая корреляция сопоставляет порядок объектов по двум показателям. Она удобна, если важна согласованность ранжирования, а не линейная зависимость значений.

Например, BLEU и chrF могут по-разному оценивать величину сходства, но сходным образом упорядочивать сегменты.

Согласованность двух метрик не означает согласованности с человеческой оценкой. Для неё нужен отдельный набор разметки.

Интерполяция и экстраполяция

Интерполяция оценивает значение внутри области наблюдений, экстраполяция — за её пределами. При прогнозе длины перевода область задаётся длинами и типами обучающих сегментов.

Для коротких кнопок модель, обученная только на длинных абзацах, может давать ненадёжный прогноз.

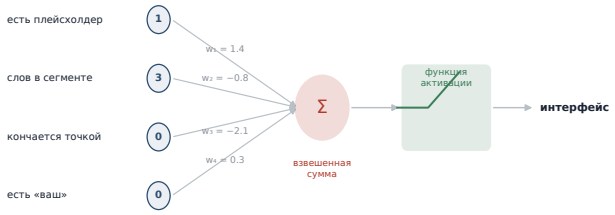
Обе операции применимы к числовым признакам текстов. Однако смысловую близость строк нельзя свести к промежуточной точке на прямой.

Нейронная сеть: место в обработке текста

Нейронная сеть получает числовые представления и последовательно их преобразует. Выход зависит от задачи: метки классов, вектор сегмента или распределение токенов.

В локализации часто используют уже обученную сеть, а качество её результата проверяют на своих материалах.

Искусственный нейрон



Обучение — это подбор весов w по размеченным примерам. Признаки здесь названы по-человечески; в реальной модели их тысячи и имён у них нет.

Нейрон вычисляет $h = \varphi(\sum_j w_j x_j + b)$. Веса определяют вклад признаков, смещение — сдвиг суммы, активация — её преобразование.

Параметры подбирают по функции потерь. Для сети из нескольких слоёв градиенты вычисляют обратным распространением ошибки.

Функции активации

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}$$

ReLU используется во многих скрытых слоях. Сигмоида подходит, например, для вероятности в бинарной классификации и для управляющих элементов рекуррентных сетей.

В трансформерах встречаются GELU и другие активации. Единой функции для всех архитектур нет.

Обучение сети

$$\theta \leftarrow \theta - \eta \nabla_\theta L$$

Функция потерь L задаёт критерий ошибки. Градиент показывает направление её локального роста по параметрам; шаг с минусом направлен на уменьшение потерь.

Потери на обучении и качество на новых данных проверяют отдельно. Снижение одного показателя не гарантирует улучшения другого.

Токенизация в языковых моделях

Подсловная токенизация разбивает строку на элементы конечного словаря. Частое слово может стать одним токеном, редкое — несколькими.

Границы токенов не обязаны совпадать с морфемами. Число токенов русской строки зависит от конкретного токенизатора.

Нельзя заранее назначить универсальный коэффициент «русский текст всегда вдвое длиннее английского». Проверяют реальные строки и выбранную модель.

Токены, эмбеддинги и позиции



Слои трансформера изменяют вектор каждой позиции с учётом доступного контекста.

Одинаковый токен может получить разные контекстные представления в разных предложениях. Начальный вектор выбирается из общей таблицы.

Механизм внимания

Внимание вычисляет веса взаимодействия между позициями и строит взвешенную сумму их представлений.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q, K, V — обучаемые проекции входных векторов; d_k — размерность ключа. Softmax превращает оценки связей в нормированные веса.

Доступ к контексту



Синие клетки — доступные позиции. Серые — будущие позиции, закрытые маской.

При предсказании следующего токена модель использует текущий префикс. В двунаправленном кодировщике ограничение другое.

Это схема доступности, а не измеренные веса внимания. Маска не гарантирует правильного использования доступного контекста.

Стоимость полного внимания

В полном самовнимании оцениваются связи между парами позиций. Для последовательности длины n матрица оценок содержит n^2 элементов.

Удвоение длины увеличивает размер этой матрицы в четыре раза. Стоимость всей модели зависит также от остальных слоёв и реализации.

Это свойство полного внимания. Разреженные и иные варианты могут иметь другую зависимость от длины.

GPT: авторегрессионный трансформер

Семейство GPT использует декодерную архитектуру: по предыдущим токенам оценивается распределение следующего. Название раскрывается как Generative Pre-trained Transformer.

Предобучение по продолжениям текста создаёт общую основу. Дополнительное обучение может настраивать выполнение инструкций и другие свойства.

Описание архитектуры не является гарантией достоверности ответа. Сохранность смысла проверяют по оригиналу и контексту.

Предобучение и дообучение

Предобучение. Получение общих представлений и закономерностей на большом наборе данных.

Задача может состоять в предсказании следующего токена или восстановлении скрытых элементов.

Дообучение. Продолжение обучения для нужного домена, формата или способа ответа.

Время и необходимый объём данных зависят от размера модели и постановки задачи.

Применение модели к переводу

Выбрать сегменты, характерные для проекта. Получить перевод готовой моделью. Сопоставить его с оригиналом, терминологией и техническими ограничениями.

Сравнивать версии модели при одинаковых условиях. Результат усреднения дополнить разбором критических ошибок.

Методы и лабораторные работы

Задача	Средства	Практика
Тип контента	TF-IDF и классификатор	Л.р. № 1
Подсказка из памяти	Левенштейн, LSA, эмбеддинги	Л.р. № 2
Качество перевода	Метрики, правила, ручная разметка	Л.р. № 3
Генерация	N-граммная модель, GRU	Л.р. № 4

Вопросы для обсуждения

Как отличить необычный, но корректный сегмент от ошибочного?

Почему высокая корреляция метрик не доказывает их пригодность для приёмки?

Что изменится, если удалить пунктуацию перед проверкой подстановочных полей?

Какие различия между предобучением и применением модели важны для проекта?

Источники

Vaswani et al. (2017): Attention Is All You Need.

Jurafsky, Martin: Speech and Language Processing.

scikit-learn: анализ данных и оценка моделей.

Учебный корпус и его описание: папка data; подготовка данных и оценка: лабораторные курса.