

ЛАБОРАТОРНАЯ РАБОТА № 1

Классификация текстов

Как лингвистическое решение превращается в число

Корпус: 160 сегментов локализации, четыре типа контента. Все числа на слайдах получены на нём и проверяются автоматически при каждом изменении кода.

Что делаем в этой работе

Задача: по тексту сегмента определить, к какому типу контента он относится. Это настоящая задача локализации — от типа зависит, кому сегмент отдавать и по какой ставке.

Техническая часть

Четыре шага scikit-learn, базовое решение, векторизация, матрица ошибок. Это каркас, он одинаков для любой задачи классификации.

Главная часть

Как предобработка текста влияет на качество — и почему именно так. Ответ на «почему» должен быть лингвистическим, а не «так вышло».

Что оценивается. Не точность вашей модели. Объяснение, почему одна настройка признаков обыграла другую. Модель обучает библиотека, объясняет лингвист.

Данные

тип	что это
интерфейс	кнопки, подсказки, ошибки
документация	руководства, справка
маркетинг	рекламные тексты
юридический	договоры, политики

По **40** сегментов каждого типа — корпус сбалансирован намеренно.

Столбцы корпуса:

en — исходный текст

ru_ref — эталонный перевод

ru_mt — машинный перевод

В этой работе используется только ru_ref. ru_mt понадобится в работе № 3.

160 сегментов — это мало. Настолько мало, что одна случайная разбивка на обучение и контроль ничего не докажет. Поэтому везде дальше — пятикратная кросс-валидация, и рядом с точностью всегда стоит разброс между долями.

Базовое решение: с чем сравнивать

Прежде чем радоваться точности, нужно знать, сколько даёт бессмысленная модель. Иначе «точность 0,5» ни о чём не говорит.

Наивнее некуда

Всегда отвечать самым частым классом. На сбалансированном корпусе из четырёх типов это ровно одна четверть.

0,250 — вот отметка, выше которой начинается смысл.

Зачем это нужно в проекте

Заказчик спросит «модель хорошая?». Правильный ответ — «лучше базового решения на столько-то», а не абсолютное число.

На несбалансированных данных baseline бывает 0,9 — и тогда «точность 0,88» означает, что модель хуже, чем ничего.

Текст → числа

Число вхождений слова: сколько раз слово встретилось в этом тексте

«Не удалось сохранить файл»	0	1	1	0	1	1
«Файл сохранён»	0	0	0	1	0	1
«Сохранить файл как...»	1	0	1	0	0	1
	как	не	сохранить	сохранён	удалось	файл

«сохранить» и «сохранён» — два разных столбца: машина не знает, что это формы одного слова

Модель не видит текста. Она видит таблицу чисел, и всё, что вы знаете о языке, попадает в неё ровно одним способом — через то, **как вы построили эту таблицу.**

Мешок слов: сколько раз встретилось слово. Порядок слов теряется полностью.

TF-IDF: то же, но частые во всём корпусе слова весят меньше. «Настройки» в корпусе локализации — почти служебное слово.

→ **векторизация текста** — признаки переключаются мышью, число столбцов видно сразу.

Первый результат

TF-IDF по словам, настройки по умолчанию, наивный Байес (раздел 7):

0,444


Базовое решение — 0,250. Почти вдвое лучше бессмыслицы, и это всё, что пока можно сказать.

Признаков: **679** — столько разных слов в 160 сегментах.

Разброс между долями — 0,085. На одной пятой корпуса модель даёт 0,31, на другой 0,56. Любое сравнение двух настроек, различающихся на 0,02, — это сравнение шума с шумом.

В отчёте разброс приводить обязательно.

Какие ошибки делает модель



Матрица ошибок отвечает не на вопрос «сколько ошибок», а на вопрос *какие*: какой класс с каким смешивается.

Читается по-лингвистически: путаются документация, маркетинг и юридический текст — все трое состоят из полных предложений с подлежащим и сказуемым.

Интерфейс не путается почти ни с чем: короткие безглагольные строки, часто без финальной точки, ни на что больше не похожи.

→ **векторизация текста** — та же матрица, но признаки переключаются на ходу.

Лингвистическая предобработка: стемминг

Русский язык флективный: «настройка», «настройки», «настройкам», «настройками» — для мешка слов это четыре разных редких признака.

Что делает стемминг

Отрезает окончание, сводя все формы к одной основе. Четыре редких признака становятся одним частым.

Точность: **0,444** → **0,538**.

Признаков: 679 → 555.

Чего он не делает

Стеммер режет по правилам, а не по словарю: он одинаково спокойно отрежет то, что окончанием не является.

Это не лемматизация. Основы, которые он выдаёт, могут не быть словами русского языка — и это нормально, модели слова не нужны.

+0,094 при разбросе до 0,135: планки перекрываются, и по одной таблице стемминг лучшим не назвать.

Главный результат работы

Признаки не по словам, а по **буквосочетаниям внутри слов** — символьные n-граммы. На том же Байесе:

0,612–0,631

Стемминг — 0,538, слова — 0,444.

«настройк», «астрой», «строй» — модель получает основу, не зная о существовании основ.

Цена: 5418–7821 признаков вместо 679. На 160 сегментах это мгновенно, на миллионе — уже нет.

Почему это работает на русском

Символьные n-граммы решают морфологическую проблему *мимо* морфологии. Совпадающие куски слов у разных словоформ общие — этого достаточно.

Побочно ловится и то, чего стеммер не видит: опечатки, латиница внутри русского текста, плейсхолдеры.

Все настройки рядом

конфигурация	точность	разброс	признаков
базовое решение	0,250	—	—
TF-IDF по умолчанию	0,444	0,085	679
без нижнего регистра	0,419	0,064	705
со стоп-словами	0,419	0,090	637
слова + биграммы	0,456	0,076	1381
min_df=2	0,381	0,061	99
стемминг	0,538	0,135	555
символьные 3-5	0,631	0,098	7821
символьные 2-4	0,612	0,102	5418

Наивный Байес, пятикратная кросс-валидация — таблица раздела 8. Отказ от нижнего регистра и стоп-слова *ухудшают* результат, min_df=2 выбрасывает редкие слова — и с ними почти всю различающую информацию. 3-5 и 2-4 расходятся на 0,019 при разбросе 0,1: разница не установлена.

Модель тоже важна — но меньше

Раздел 9: лучшие признаки (символьные 2–4) оставляем, меняем классификатор.

модель	точность	разброс
наивный Байес	0,612	0,102
логистическая регрессия	0,744	0,100
ближайшие соседи, $k = 5$	0,550	0,064

Модели расходятся на **0,19**; предобработка на одном Байесе — на **0,25**. Признаки чуть сильнее, но это величины одного порядка.

Признаки и модель выбирают вместе. С Байесом чуть лучше смотрелись n -граммы 3–5, с логистической регрессией выигрывают 2–4: 0,744 против 0,713.

→ **векторизация текста** — модель и длина n -грамм — два переключателя, проверьте сами.

Средняя точность прячет главное

Две настройки могут дать одинаковую точность и при этом ошибаться на совершенно разных сегментах. Среднее этого не показывает никогда.

Что смотреть вместо среднего

Список сегментов, у которых ответ *изменился* при смене признаков: что исправилось, что испортилось, что как было неверным, так и осталось.

→ **векторизация текста** — вкладка «Что изменилось» показывает ровно эти сегменты.

Зачем это в проекте

«Мы подняли точность на 3 %» — и одновременно сломали класс, который заказчику важнее остальных. Такое видно только пересегментно.

Что должно быть в отчёте

Обязательно

1. Базовое решение и сравнение с ним.
2. Точность *и разброс* для каждой настройки.
3. Матрица ошибок с разбором: какие классы путаются.
4. Объяснение результата свойствами русского языка.

Не принимается

«Символьные n-граммы показали лучший результат» — это пересказ таблицы, а не объяснение.

Нужно: почему буквосочетания обыгрывают слова именно на русском, и что было бы на языке с бедной морфологией.

Проверьте себя одним вопросом. Если бы корпус был английский — какая настройка выиграла бы и насколько? Ответ на него показывает, поняли вы результат или запомнили.

Что унести из работы № 1

Про машинное обучение

Выбор признаков решает не меньше, чем выбор модели: на одном Байесе от 0,381 до 0,631, между моделями на лучших признаках — от 0,550 до 0,744.

Любое число нужно сравнивать с базовым решением и приводить вместе с разбросом.

→ **векторизация текста** — все настройки этой работы переключаются мышью; с наивным Байесом таблица совпадает с разделом 8.

→ **данные и разметка** — кривая обучения и три средства раздела 13 (к заданию 8).

Про профессию

Место лингвиста в этой схеме — ровно там, где текст превращается в числа. Это не подготовительная работа перед «настоящим» машинным обучением, это и есть решающий шаг.