ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Классификация текстов

Лабораторная работа № 1: признаки, модели и языковой разбор ошибок

Цифровая лингвистика и локализация
Учебные примеры связаны с корпусом и лабораторными работами курса.

Цель лабораторной работы

По русскому тексту сегмента определить тип контента. Сравнить способы представления текста и объяснить, какие языковые свойства повлияли на результат.

Основной результат — воспроизводимое сравнение и разбор ошибок. Одного значения точности для вывода недостаточно.

Корпус и разметка

Класс	Примеры	Объём
Интерфейс	Кнопки, подсказки, сообщения об ошибках	40 сегментов
Документация	Инструкции и справка	40 сегментов
Маркетинг	Описание преимуществ продукта	40 сегментов
Юридические тексты	Условия использования и договоры	40 сегментов

В работе используются `ru_ref` и метка типа. Машинный перевод `ru_mt` понадобится в Л.р. № 3.

Схема эксперимента

В каждом разбиении повторяется полный цикл. Правильные метки контрольной части используются только для оценки.



Векторизатор и классификатор объединяют в Pipeline. При сравнении меняют одну настройку, сохраняя разбиения и критерий оценки.

Базовый уровень качества

Базовое решение всегда выбирает один, самый частый класс. При четырёх равных классах оно даёт accuracy = 0,250.

На реальном проекте распределение может быть другим. Базовое качество нужно вычислять заново.

Если 90 % сегментов относятся к одному классу, постоянный ответ этим классом даст 0,90. Такая оценка ещё не означает полезного распознавания остальных классов.

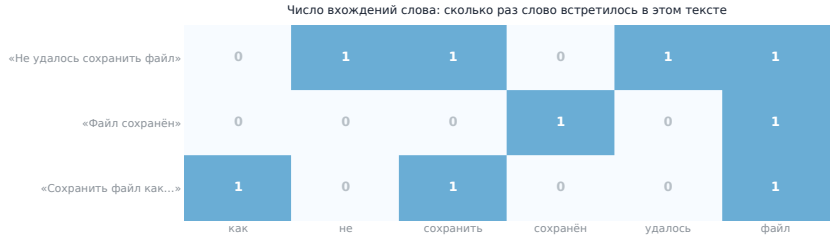
Токенизация

Токенизация — разбиение текста на единицы по заданным правилам. Для словесной модели результатом обычно служат слова и, при необходимости, отдельные знаки.

В локализации важно заранее решить, как обрабатывать дефисы, числа, теги и подстановочные поля.

`{name}` — подстановочное поле: при работе программы его заменяют значением. Скобки и имя поля нужно сохранить в переводе.

Мешок слов



«сохранить» и «сохранён» — два разных столбца: машина не знает, что это формы одного слова

Координата вектора соответствует слову из словаря. Значение показывает число его вхождений. Порядок слов в таком представлении теряется.

«Не удалось подключиться» и «Удалось не подключиться» имеют одинаковые частоты слов, хотя различаются по коммуникативному смыслу.

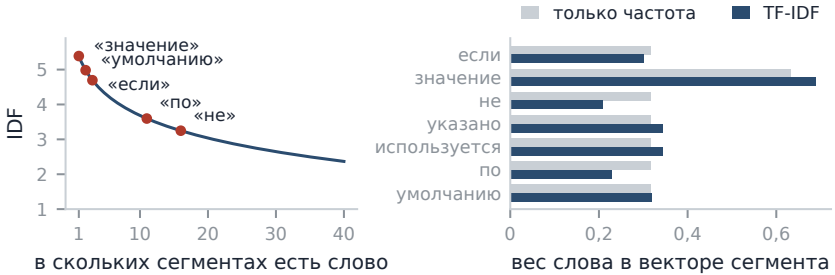
TF-IDF: частота в сегменте и редкость в корпусе

$$w(t, d) = \mathrm{tf}(t, d) \left(\ln \frac{1 + N}{1 + \mathrm{df}(t)} + 1 \right)$$

$\mathrm{tf}(t, d)$ — число вхождений слова в сегмент, $\mathrm{df}(t)$ — число сегментов со словом, N — число обучающих сегментов. Затем вектор нормируют.

Частые во всём корпусе слова получают меньший IDF. Их языковая или переводческая важность этим не определяется.

Какие слова получают большой вес



Слева показана зависимость IDF от частоты по документам; справа — пример распределения весов внутри сегмента.

Частица «не» может иметь небольшой вес и при этом полностью менять смысл сообщения.

Наивный байесовский классификатор

Модель оценивает вероятность класса по признакам. «Наивное» предположение состоит в условной независимости признаков при известном классе.

$$P(y \mid \mathbf{x}) \propto P(y)P(\mathbf{x} \mid y)$$

В мультиномиальном варианте признаки описываются частотами. В лабораторной используется MultinomialNB с неотрицательными TF-IDF-признаками.

Соседние n-граммы связаны, поэтому предположение независимости приблизительно. Полезность модели определяется проверкой на новых сегментах.

Логистическая регрессия для классификации

Для каждого класса модель вычисляет линейную оценку признаков. В многоклассовом варианте softmax преобразует оценки в вероятности.

$$z_k = \mathbf{w}_k \cdot \mathbf{x} + b_k, \qquad p_k = \frac{e^{z_k}}{\sum_m e^{z_m}}$$

Предсказание — класс с наибольшей вероятностью. Веса подбирают по размеченным обучающим примерам. Несмотря на название, модель здесь решает задачу классификации.

Подробный разбор softmax, потерь и градиента дан в блоке 2 лекции «Текст как данные».

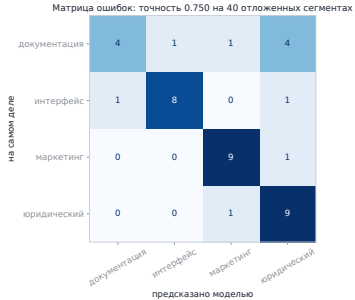
Первый результат и неопределённость

TF-IDF по словам и наивный байесовский классификатор: средняя accuracy — 0,444; стандартное отклонение по пяти разбиениям — 0,085.

Стандартное отклонение описывает разброс результатов между разбиениями. Оно не является доверительным интервалом для разницы двух моделей.

Разницу в несколько сотых нужно рассматривать на одинаковых разбиениях и сопоставлять с конкретными исправленными ошибками.

Разбор ошибок по типам контента



Проверяем, какие классы модель смешивает, и читаем сегменты из соответствующих ячеек.

Гипотезу «документация и юридические тексты похожи по синтаксису» нужно подтвердить примерами, а затем проверить изменением признаков.

Стемминг и лемматизация

Стемминг сокращает словоформу по правилам до общей последовательности символов. Результат не обязательно совпадает с лингвистической основой.

Например, разные формы слова могут получить общий фрагмент «изменен».

Лемматизация приводит словоформу к словарной форме. Для омонимичных форм может потребоваться контекст.

«Стали» может относиться к лемме «стать» или «сталь».

Что изменилось после стемминга

Число признаков сократилось с 679 до 555. Средняя accuracy выросла с 0,444 до 0,538; стандартное отклонение стало 0,135.

Вероятное объяснение: разные формы стали общими признаками. Его проверяют на сегментах, предсказания для которых изменились.

Стемминг может также объединить разные слова. Рост среднего в одном опыте не гарантирует улучшения на другом корпусе.

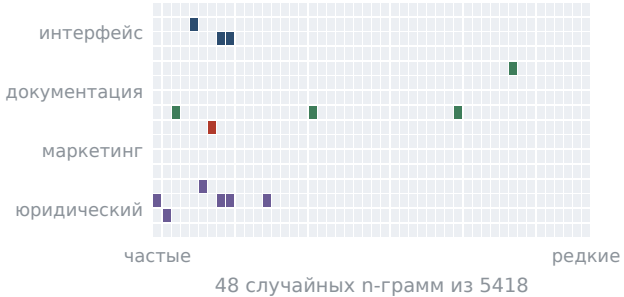
Символьные n-граммы

Символьная n-грамма — последовательность из n соседних символов. В качестве признаков используют, например, фрагменты длиной от 2 до 4.

«сохранить»: сох, охр, хра, ран, ани, нит, ить. Часть фрагментов совпадает с «сохранение».

Общие фрагменты позволяют связать словоформы без морфологического словаря. Фрагмент может также пересекать границу морфемы или слова.

Разреженность текстовой матрицы



Большинство координат равны нулю: каждый сегмент содержит лишь небольшую часть всех признаков корпуса.

Для n-грамм 2–4 словарь полного корпуса содержит 5418 признаков. Внутри кросс-валидации словарь обучающей части меньше.

Сравнение признаков при одном классификаторе

Настройка	Средняя accuracy	Станд. отклонение
TF-IDF по словам	0,444	0,085
С удалением стоп-слов	0,419	0,090
Слова и словесные биграммы	0,456	0,076
Минимальная частота 2	0,381	0,061
Стемминг	0,538	0,135
Символьные n-граммы 2–4	0,612	0,102
Символьные n-граммы 3–5	0,631	0,098

Наивный байесовский классификатор, пять разбиений. Удаление редких слов на маленьком корпусе может лишить модель полезных признаков.

Сравнение моделей

При фиксированных символьных n-граммах 2–4 логистическая регрессия в лабораторной достигает средней accuracy 0,744. Наивный байесовский классификатор с теми же признаками даёт 0,612.

Сначала сравнивают признаки при одной модели, затем модели при фиксированных признаках. Так можно объяснить источник изменения качества.

Из одного опыта нельзя вывести, что признаки всегда важнее алгоритма. Вклад зависит от корпуса, задачи и исходной конфигурации.

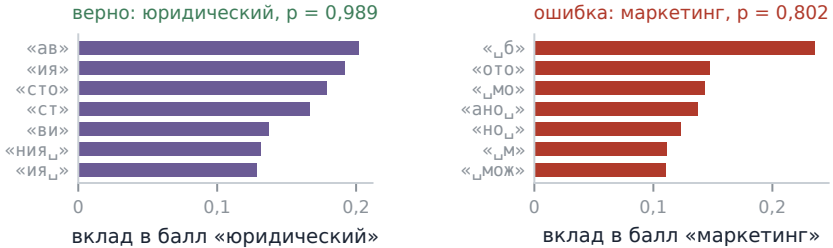
Почему словесные признаки теряют короткие строки

В контрольной части может оказаться сегмент, у которого ни одно слово не встречалось в обучающей. Его словесный вектор окажется нулевым.

В опыте курса таких сегментов 44 из 160. При символьных n-граммах пустых векторов в этих разбиениях нет.

Общие части слов повышают покрытие. Это не означает, что модель автоматически распознаёт морфемы и их функции.

Интерпретация решения линейной модели



Вклад признака в оценку класса равен $w_{kj}x_j$. Можно выделить фрагменты, которые сильнее всего повлияли на ответ.

Большой вклад показывает связь в модели. Чтобы назвать её грамматической закономерностью, нужны контексты и проверка на новых данных.

Как избежать утечки данных

Не вычислять словарь и IDF по всему корпусу до кросс-валидации. Не подбирать настройки по окончательной тестовой выборке.

Проверить близкие дубликаты. Если сегменты относятся к одному документу или шаблону, использовать групповое разбиение при оценке переноса на новые документы.

Отчёт: результат и объяснение

Указать признаки, модель, разбиения и случайное зерно. Привести среднюю accuracy, стандартное отклонение и матрицу ошибок.

Разобрать несколько изменившихся предсказаний: текст, правильный класс, ответы двух моделей и языковое объяснение. Отдельно указать, что осталось непроверенным.

Вопросы для обсуждения

Почему удаление стоп-слов может ухудшить классификацию русских интерфейсных строк?

Какие общие n-граммы связывают «сохранить» и «сохранение»? Какие различия при этом теряются?

Как проверить, переносится ли результат на новый продукт?

→ **векторизация и классификация** — параметры и результаты можно сравнить на примерах корпуса.

Источники

scikit-learn: извлечение текстовых признаков.

scikit-learn: кросс-валидация и разбиение данных.

Числа и примеры: Л.р. № 1, корпус курса и графики лекции «Текст как данные».