ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Векторные представления и память переводов

Лабораторная работа № 2: сходство строк, поиск и интерпретация результатов

Цифровая лингвистика и локализация
Учебные примеры связаны с корпусом и лабораторными работами курса.

Цель работы

Сравнить меры сходства при поиске по памяти переводов. Объяснить расхождения на конкретных запросах и выбрать способ проверки подсказок.

Одинаковый процент или косинус у разных методов не означает одинаковую полезность для переводчика.

Память переводов

Память переводов (translation memory, TM) — база пар «исходный сегмент — перевод». При поступлении нового сегмента система ищет похожие исходные сегменты и предлагает связанные переводы.

В учебной работе поиск выполняется по русской стороне корпуса. Это удобно для разбора морфологии и перефразирования; направление отличается от обычного поиска нового оригинала в TM.

Точное и нечёткое совпадение

При точном поиске строки должны совпасть по заданным правилам нормализации. Нечёткий поиск ранжирует кандидатов по мере сходства.

Алгоритм возвращает ближайший сегмент даже тогда, когда подходящего перевода в памяти нет.

Нужно проверять не только порядок кандидатов, но и достаточность сходства. Ближайший ответ может оказаться непригодным.

Расстояние Левенштейна

Расстояние Левенштейна — минимальное число вставок, удалений и замен символа, необходимых для преобразования одной строки в другую.

«кот» и «кит»: одна замена. «кот» и «скот»: одна вставка. Для «кот» и «скоты» нужны две вставки.

В этом определении перестановка двух символов не является отдельной операцией. Для неё существуют другие варианты редакционного расстояния.

Как вычисляют редакционное расстояние

$$D_{i,j} = \min \begin{cases} D_{i-1,j} + 1 \\ D_{i,j-1} + 1 \\ D_{i-1,j-1} + [a_i \neq b_j] \end{cases}$$

$D_{i,j}$ — расстояние между первыми i и j символами строк. Три случая соответствуют удалению, вставке и замене; совпавшие символы не требуют правки.

Начальные значения: $D_{i,0} = i$, $D_{0,j} = j$. Таблица строится от коротких префиксов к полным строкам.

Нормированный процент сходства

$$s(a, b) = 100 \left(1 - \frac{D(a, b)}{\max(|a|, |b|)}\right)$$

$|a|$ и $|b|$ — длины строк. Для совпадающих строк результат равен 100 %. Случай двух пустых строк обрабатывают отдельно.

Это формула учебной работы. Конкретные CAT-системы могут иначе учитывать теги, числа, порядок слов и штрафы.

Косинусное сходство

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\sum_j a_j b_j}{\sqrt{\sum_j a_j^2}\sqrt{\sum_j b_j^2}}$$

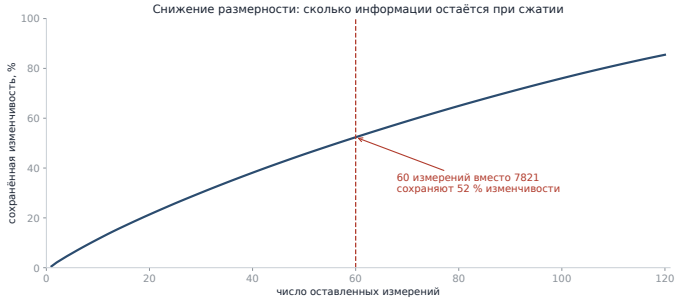
Косинус сравнивает направления ненулевых векторов. Для неотрицательных TF-IDF-векторов лежит от 0 до 1; для произвольных векторов возможны отрицательные значения.

Умножение всего вектора на положительное число косинус не меняет. Добавление новых слов меняет направление и может изменить сходство.

Четыре способа сравнения

Метод	Основа сравнения	Ограничение
Левенштейн	Последовательность символов	Чувствителен к перестановкам
TF-IDF n-грамм	Общие фрагменты символов	Не распознаёт синонимы напрямую
LSA	Компактные координаты TF-IDF	Зависит от связей в учебном корпусе
Готовые эмбеддинги	Предобученное представление	Могут сближать несовместимые фразы

LSA и усечённое SVD



LSA — латентно-семантический анализ. Усечённое сингулярное разложение (SVD) заменяет тысячи исходных координат меньшим числом компонент. В работе рассматриваются 60 компонент.

Сжатие сглаживает некоторые различия, но может удалить полезные признаки. Улучшение поиска проверяют на запросах.

Эмбеддинги: что означает близость

Эмбеддинг — плотный числовой вектор, полученный обученной моделью. Сходство таких векторов может отражать близость тематики и употребления.

Синонимичные строки могут оказаться близкими даже без общих слов. Строки с противоположным смыслом тоже могут быть близки, если отличаются одним отрицанием.

Векторы в папке data уже вычислены. Для новых текстов требуется запуск совместимой модели эмбеддингов.

Один запрос, несколько оценок

Запрос: «Сохранить все изменения». Близкий сегмент: «Сохранить изменения».

В опыте курса: сходство по Левенштейну — 82,6 %, косинус по символьным n-граммам — 0,909, по готовым эмбеддингам — 0,958.

Значения относятся к разным шкалам. Они не являются вероятностью правильности подсказки.

Проверочный набор запросов

В работе 13 запросов с разными изменениями: добавлением слова, заменой термина, перестановкой, перефразированием и другими правками.

Левенштейн и символьные n-граммы возвращают один и тот же ближайший сегмент для 9 запросов. Оставшиеся 4 особенно полезны для сравнения методов.

Перестановка и изменение словоформ

Запрос: **«Настройки поиска»**.

Левенштейн: «Начните за три простых шага.», 28,6 %.

N-граммы: «Поиск по настройкам», косинус 0,696.

Левенштейн учитывает порядок символов. Общие n-граммы сохраняются и при изменении порядка слов и окончаний.

Запрос одновременно меняет порядок и грамматическую форму. Чтобы изучить только один фактор, нужен отдельный минимальный пример.

Номинализация и коммуникативная функция

Запрос: «Сохранение изменений». Левенштейн находит «Сохранить изменения» (75,0 %), n-граммы — «Изменения сохранены» (0,760).

Фразы относятся к одному действию, но выполняют разные функции: название процесса, команда и сообщение о результате.

Лексическое сходство не делает строки взаимозаменяемыми. Подходящая подсказка зависит от того, где строка используется.

Короткая подсказка для длинного запроса

Запрос: «Пожалуйста, очистите кэш и повторите попытку». N-граммы находят «Очистить кэш» с косинусом 0,591.

Короткий кандидат покрывает только часть инструкции. Нормированное редакционное расстояние дополнительно учитывает несовпадение длины.

Частичную подсказку можно использовать при редактировании. Автоматически заменять ею весь запрос нельзя.

Перефразирование без общих слов

Запрос: «По вашему запросу результатов нет». Ожидаемая подсказка: «Ничего не найдено».

Левенштейн, n-граммы и LSA не помещают её в первую тройку. Готовые эмбеддинги находят её на втором месте.

Результат оценивают по нескольким позициям списка. Один неудачный первый ответ ещё не описывает весь поиск.

Оценка поиска: Hit@k

$$\text{Hit@}k = \frac{\text{запросы с нужным ответом в первых } k}{\text{запросы с известным нужным ответом}}$$

Для каждого запроса заранее определяют пригодные подсказки. Затем проверяют, попала ли хотя бы одна из них в первые k результатов.

Если подходящего сегмента в памяти нет, такой запрос нужен для отдельной проверки отказа от подсказки.

Порог сходства и число подсказок

Порог Левенштейна	Показано подсказок	Из них пригодны
60 %	10	9
70 %	9	8
75 %	7	6
80 %	5	5
90 %	2	2

13 учебных запросов. Более высокий порог сокращает число подсказок, но вместе с ошибочными может скрыть полезные.

Точность отбора и полнота

Точность отбора (precision) — доля пригодных подсказок среди показанных. Полнота (recall) — доля найденных пригодных подсказок среди всех доступных.

При пороге 75 % точность показанных подсказок равна 6/7. Для полноты нужен заранее размеченный набор запросов, где подсказка действительно существует.

Порог выбирают по цене пропуска и лишней проверки. На маленьком наборе он служит демонстрацией компромисса.

Кластеризация сегментов

Кластеризацию используют для обзора корпуса без готовых меток. В работе k-средних сравнивается на TF-IDF, LSA и готовых эмбеддингах.

ARI позволяет проверить, насколько найденные группы совпали с типами контента. Низкое совпадение не объясняет его причины автоматически.

Разметка и кластеры



Слева показаны категории контента, справа — результат кластеризации на готовых эмбеддингах.

Двумерный рисунок помогает увидеть структуру, но качество сравнивают в исходном пространстве признаков.

Устойчивость кластеризации

Представление	ARI одного запуска	Диапазон 8 запусков
Символьные n-граммы	0,079	0,015–0,079
LSA	0,043	0,017–0,122
Готовые эмбеддинги	0,172	0,143–0,234

Значения зависят от инициализации и вычислительной среды. Эмбеддинги здесь лучше совпадают с разметкой, но соответствие остаётся слабым.

Терминологические кандидаты

Слова с высоким средним TF-IDF внутри типа контента можно рассмотреть как кандидатов в характерную лексику. Сравнение с другими типами помогает выделить отличия.

Редкость слова и связь с категорией ещё не делают его термином. Нужно проверить обозначаемое понятие, употребление и варианты перевода.

Составьте небольшой список кандидатов и приведите контексты, по которым вы включили или исключили каждую единицу.

Что включить в отчёт

Сравнить четыре меры на 13 запросах, подробно разобрать расхождения и коммуникативную функцию кандидатов.

Объяснить выбор порога. Привести ARI и диапазон по запускам. Разобрать терминологические кандидаты.

Общий вывод должен связывать метод с типом правки: перестановкой, словоформой, синонимией или изменением функции строки.

→ **поиск по памяти переводов** — параметры и результаты можно сравнить на примерах корпуса.

Источники

scikit-learn: косинусное сходство.

scikit-learn: скорректированный индекс Рэнда.

Примеры и числа: Л.р. № 2, корпус курса, готовые эмбеддинги из папки data.