

ЛАБОРАТОРНАЯ РАБОТА № 2

Векторные представления и память переводов

Четыре способа измерить «похоже» — и четыре разных ответа

Память переводов на 160 сегментов, 13 запросов. Работа кончается двумя отрицательными результатами — это и есть её содержание.

Память переводов — это уже поиск по векторам

САТ-инструмент, в котором вы работаете каждый день, делает ровно то, что в этой работе разбирается по частям: берёт новый сегмент, находит в базе самый похожий и показывает процент совпадения.

Что решает инструмент

Какой сегмент считать «самым похожим» и по какой мере похожести. От этого зависит, что подставится в ваше окно перевода.

Что решаете вы

Порог, ниже которого подсказка не показывается. Обычно 75 %. Это не техническая настройка, а решение о цене ошибки.

Обучения здесь нет. Ни одна модель в этой работе ничему не учится на ваших данных. Всё решает выбор представления — то есть снова решение лингвиста, а не алгоритма.

Процент совпадения: как он считается

Расстояние Левенштейна — сколько посимвольных правок нужно, чтобы превратить один сегмент в другой.

Процент совпадения:

$$\left(1 - \frac{\text{правок}}{\max(\text{длин})}\right) \times 100$$

Именно это число САТ-инструмент показывает как «82 %».

Что эта мера не умеет

Она работает с последовательностью символов и ничего не знает о словах.

Переставьте два слова местами — и расстояние будет огромным, хотя для переводчика сегмент почти тот же.

Это не дефект реализации, это определение меры.

Первый пример: меры согласны

Запрос:

«**Сохранить все изменения**»

Находится в памяти:

«**Сохранить изменения**»

Левенштейн: **82,6 %**

Косинус по символьным n-граммам:

0,909

Готовые эмбединги: **0,958**

Добавлено одно слово — и все три меры указывают на один и тот же сегмент.


На таких примерах кажется, что выбор меры не важен. Вся работа — про то, что происходит дальше.

Четыре меры похожести

мера	что сравнивает	чего не видит
Левенштейн	символы подряд, с учётом порядка	перестановку слов, синонимы
символьные n-граммы	куски слов длиной 3–5, без учёта порядка	синонимы; страдает от разной длины
LSA	то же, сжатое до 60 измерений через SVD	синонимы, которых нет в этом корпусе
готовые эмбединги	смысл, выученный на большом корпусе заранее	редкую терминологию проекта

Первые три считаются по вашему корпусу и целиком в браузере. Четвёртая — результат чужого обучения на сотнях миллионов предложений; её нельзя посчитать на месте, векторы приходят готовыми.

Что делает LSA: 60 измерений вместо 7821



Символьные n -граммы дают **7821** признак — больше, чем сегментов в корпусе. SVD оставляет 60 направлений и сохраняет **52 %** изменчивости.

Сжатие не добавляет знания о языке: оно убирает шум, а с ним часть сигнала. LSA не выиграл ни одного запроса у n -грамм, из которых получен.

13 запросов: где меры расходятся

Каждый запрос — это эталонный сегмент с одной намеренной правкой. Левенштейн и символьные n-граммы дают один и тот же ответ на 9 запросах из 13.

Меры согласны — 9 запросов

добавлено слово
заменён термин
изменено число
заменена концовка
похожего сегмента нет

Меры расходятся — 4 запроса

переставлены слова
номинализация
короткий сегмент внутри длинного
синонимия без общих слов

Совпадение на девяти запросах не означает, что мера не важна: это означает, что девять правок были простыми. Работа — про четыре оставшихся.

Расхождение 1: порядок слов

Запрос: «Настройки поиска»

Левенштейн → «Начните за три
простых шага.» 28,6 %

n-граммы → «Поиск по настройкам»
0,696

Почему

Для Левенштейна перестановка слов
— это почти полная перезапись строки.
Он честно находит ближайшее по
символам, и это случайный сегмент.

Мешок n-грамм порядка не видит
вовсе — и именно поэтому
выигрывает.

Слепота к порядку слов здесь оказалась достоинством. В другой задаче она же будет дефектом — «собака укусила человека» и «человек укусил собаку».

Расхождения 2 и 3: оба ответа защитимы

Номинализация

Запрос: «Сохранение изменений»

Левенштейн → «Сохранить
изменения» **75,0 %**

n-граммы → «Изменения сохранены»
0,760

Оба сегмента уместны, различаются
грамматикой. Выбирает человек.

Короткий сегмент в длинном запросе

Запрос: «Пожалуйста, очистите кэш и
повторите попытку»

Левенштейн → мимо **29,5 %**

n-граммы → «Очистить кэш» **0,591**

Левенштейн делит на длину —
длинный запрос штрафует сам по
себе.

Ни одна из мер не «ошиблась». Они отвечают на разные вопросы, и вопрос выбирает тот, кто настраивает инструмент.

Расхождение 4: синонимия

Запрос: «По вашему запросу
результатов нет»

Нужный ответ: «Ничего не найдено»

Общих слов — ноль. Поэтому:

Левенштейн — не находит

n-граммы — не находит

LSA — не находит

Ни один из трёх не ставит нужный
сегмент даже в первую тройку.

→ **память переводов** — этот запрос можно прогнать всеми четырьмя мерами сразу.

Готовые эмбединги

Находят — на **2-м** месте. Первым идёт
другой сегмент.

Это честный результат работы:
средство, которое должно было
решить проблему, решает её *не до
конца*.

В CAT-инструменте это значит, что
подсказка будет — но переводчику
придётся её заметить среди других.

Порог 75 % — это решение, а не настройка

порог	подсказок	верных
60 %	10	9
70 %	9	8
75 %	7	6
80 %	5	5
90 %	2	2

Из 13 запросов.

Отраслевой порог в 75 % на этих запросах прячет почти половину памяти: подсказка есть, но переводчик её не увидит.

Поднять порог до 90 % — остаётся 2 подсказки из 13, зато обе верные.

Это компромисс, а не оптимум. Что дороже — пропущенная подсказка или подсказка, которую придётся править, — знает менеджер проекта, а не алгоритм.

Второй отрицательный результат: кластеризация

Если сегменты хорошо представлены числами, похожие должны собираться вместе сами — без разметки. Совпадут ли кластеры с типами контента?


представление	ARI	разброс по восьми запускам
символьные n-граммы	0,079	0,015 – 0,079
LSA	0,043	0,017 – 0,122
готовые эмбединги	0,172	0,143 – 0,234

$ARI = 1$ — кластеры совпали с разметкой, $ARI = 0$ — совпали случайно. **Все три числа близки к нулю:** кластеризация находит длину, наличие цифр и формат, а не тип контента.

Это правильный результат, а не поломка. Тип контента придуман людьми для бизнес-процесса — данные не обязаны о нём знать.

Разметка и кластеры рядом

Кластеризация ищет группы, которые есть в данных, а не те, которые придумал человек



Слева — разметка по типам контента, справа — что нашла кластеризация на готовых эмбедингах, лучше из трёх представлений. Границы не совпадают нигде: **кластеры реальные, но это не типы контента.**

Почему ARI нельзя приводить с тремя знаками

Разброс по восьми запускам у символьных n-грамм: от **0,015** до **0,079**.

Это *шире*, чем разница между символьными n-граммами и LSA.

Кроме того, k-means на разреженной матрице приходит к разному локальному минимуму в зависимости от библиотеки линейной алгебры: на одной машине 0,079, на другой 0,023.

→ **память переводов** — вкладка «Кластеризация» показывает ARI вместе с разбросом по запускам.

Что из этого следует

Число в три знака здесь описывает не корпус, а версию библиотеки и номер запуска.

В отчёте про кластеризацию корректно писать: «ARI около нуля при любом из представлений; разброс между запусками шире разницы между ними».

Так сформулированное утверждение воспроизводится где угодно.

Что должно быть в отчёте

Обязательно

1. Разбор всех четырёх расхождений: какая мера что нашла и почему.
2. Вывод про порог: что он прячет и чем за это платят.
3. Оба отрицательных результата — синонимия и кластеризация — с объяснением, почему они закономерны.

Типичная ошибка

Объявить меру-победителя. Её нет.

Символьные n-граммы выигрывают три расхождения из четырёх — и проигрывают там, где порядок слов важен. Эмбединги решают синонимию — и требуют чужой предобученной модели, которая ничего не знает о терминологии вашего проекта.

Что унести из работы № 2

Про представления

«Похоже» — не свойство пары текстов, а свойство выбранной меры. Смена представления меняет ответ, а не уточняет его.

Отрицательный результат — тоже результат, если объяснено, почему он закономерен.

→ **память переводов** — все 13 запросов, четыре меры, порог и кластеризация — в браузере.

Про профессию

Процент совпадения в вашем САТ-инструменте — это чьё-то решение о мере и о пороге. Теперь вы знаете, какое именно, и можете спорить о нём по существу.