

Машинный перевод и оценка качества

Что метрика измеряет на самом деле

160 сегментов машинного перевода рядом с эталонным. Главный вопрос работы — не «какая метрика лучше», а «что именно каждая из них видит и чего не видит никогда».

Постановка

У каждого сегмента есть исходник, эталонный перевод и машинный перевод. Задача: решить, какие сегменты отдавать на редактуру — не читая все 160.

Два подхода

Метрики сравнивают машинный перевод с эталоном и выдают число: BLEU, chrF, TER.

Формальные проверки смотрят на сам сегмент: целы ли плейсхолдеры, на месте ли отрицание, не потеряно ли предложение.

Почему это не одно и то же

Метрика отвечает на вопрос «насколько похоже на эталон».

Проверка отвечает на вопрос «сломается ли продукт».

Работа показывает, что эти два вопроса расходятся сильнее, чем кажется.

Как считаются метрики

BLEU

Доля совпавших словесных n-грамм (обычно до 4-грамм) плюс штраф за слишком короткий перевод.

Работает со словами целиком: «сохранить» и «сохранена» для него разные слова без всякого родства.

chrF

То же самое, но по символьным n-граммам.

Поэтому на русском chrF обычно выше и спокойнее: словоформы одного слова имеют общие куски, и метрика их засчитывает.

Обе метрики измеряют совпадение формы. Ни одна из них не знает, что такое смысл, — и это не упрощение для учебных целей, это их устройство.

Средние по корпусу

На 160 сегментах:

BLEU **0,46**

chrF **0,64**

Медиана BLEU — 0,37.

И что это значит?

Само по себе — ничего.

«BLEU 0,46» нельзя перевести ни в «качество 46 %», ни в «нужно править 54 % сегментов». Число сравнимо только с другим числом, посчитанным на том же корпусе тем же способом.

Абсолютное значение BLEU не означает вообще ничего. Это первое, что нужно усвоить про метрики.

Диверсия: ломаем перевод нарочно

Сегмент s002, интерфейс: «Удалить файл «{name}»?»

что сломали	BLEU	chrF	формальная проверка
ничего не трогали	1,00	1,00	—
сломан плейсхолдер	1,00	1,00	сработала
«удалить» → «стереть»	0,63	0,65	—
переставлены два слова	0,55	0,68	—

Сломанный плейсхолдер метрики не заметили вовсе. {name} превратился в (name): пользователь увидит в диалоге «(name)» вместо имени файла, а BLEU остался 1,00. Безобидная же замена слова на синоним роняет BLEU почти вдвое.

→ **метрики машинного перевода** — эти кнопки ломают перевод, числа пересчитываются сразу.

Почему BLEU ведёт себя именно так

Плейсхолдер

Токенизатор отбрасывает пунктуацию, и {name} с (name} превращаются в одинаковые токены. Для метрики изменения не произошло.

Синоним

Одно заменённое слово рушит сразу все n-граммы, в которые оно входило: униграмму, биграмму, триграмму. На коротком сегменте это половина всех совпадений.

Вывод для практики. Тяжесть ошибки для метрики зависит от того, сколько n-грамм она задела, а не от того, во что она обойдётся пользователю. Эти две величины не связаны.

Худший случай: смысл на противоположный

Сегмент s009, интерфейс

Эталон:

«Пароль должен содержать не менее 8 символов»

Потеряно одно слово:

«Пароль должен содержать менее 8 символов»

BLEU 0,50 chrF 0,90

Формальная проверка: **молчит**

Сравните с предыдущим слайдом: замена «удалить» на «стереть» ничего не ломает и роняет BLEU до 0,63. Инверсия требования к паролю — до 0,50. Разница между катастрофой и мелочью для метрики почти неразличима.

Требование безопасности вывернуто наизнанку. chrF — 0,90: по форме сегменты почти совпадают.

Проверка на отрицание ищет «не» перед глаголом и не знает про «не менее».

Формальные проверки: что они ловят

На 160 сегментах проверки сработали на **8**.

Из них плейсхолдеры сломаны ровно в **3** сегментах: s002, s012, s028.

Остальные — потерянное отрицание и потерянное предложение.

Сильная сторона

Проверка отвечает «да» или «нет» и указывает на конкретное место. Её результат можно вставить в договор: «сегменты со сломанными плейсхолдерами не принимаются».

С BLEU так нельзя: порога, отделяющего годное от негодного, не существует.

Восемь сегментов из 160 — это пять процентов корпуса. Столько работы нужно, чтобы поймать все поломки, которые ломают продукт.

Сколько стоит отбирать сегменты по метрике

средство отбора	на проверку
формальные проверки	8
BLEU ниже медианы	78

Из 160 сегментов. Почти **десятикратная** разница в объёме ручной работы.

Отбор «всё, что ниже медианы BLEU» отправляет на редактуру **49 %** корпуса — и всё равно пропускает поломки.

Худшее из двух миров: вдесятеро больше работы и при этом не полное покрытие.

Метрика не предназначена для отбора отдельных сегментов. Она предназначена для сравнения систем на большом корпусе.

Слепое пятно, названное по имени

Сегмент **s002** в корпусе:

эталон Удалить файл «{name}»?

машина Удалить файл "(имя)"?

BLEU **0,63** — **выше** медианы 0,37.

Отбор по BLEU этот сегмент пропустит.

Формальная проверка его ловит.

→ **метрики машинного перевода** — все слепые пятна корпуса — отдельной вкладкой.

Плейсхолдер сломан и вдобавок переведён: пользователь увидит в диалоге буквально «{имя}» вместо имени файла.

Для BLEU это сегмент выше среднего качества.

Ложные срабатывания и морфология

Правило «потеряно отрицание» ищет частицу «не». На русском этого мало: отрицание бывает встроено в слово.

Ложные тревоги

«Невозможно...», «отсутствуют...» — отрицание на месте, но выражено морфологически. Правило считает его потерянным.

В корпусе таких сегментов два: s010 и s031.

Настоящая ошибка

s083 — потеряно целое предложение. После уточнения правила сегмент обязан остаться в списке.

Это и есть критерий правильной правки: ложные тревоги ушли, настоящая ошибка осталась.

Задание работы. Уточнить правило так, чтобы оно учитывало морфологическое отрицание. Проверяется не формулировка регулярного выражения, а то, что s010 и s031 ушли, а s083 остался.

Что должно быть в отчёте

Обязательно

1. Таблица диверсий с разбором, почему метрики отреагировали именно так.
2. Сравнение стоимости отбора: 8 против 78.
3. Уточнённое правило отрицания и доказательство, что s083 остался помеченным.

Не принимается

«chrF лучше BLEU для русского языка».

Это верное утверждение, приведённое без опоры. Нужно показать на конкретных сегментах, где именно chrF ведёт себя разумнее — и где он точно так же слеп, как BLEU.

Что унести из работы № 3

Про метрики

Метрика измеряет совпадение формы с эталоном. Стоимость ошибки для пользователя она не измеряет и не может.

Абсолютное значение BLEU не значит ничего. Сравнивать можно только два числа с одного корпуса.

→ **метрики машинного перевода** — сломать перевод и увидеть реакцию метрик — за один клик.

→ **данные и разметка** — порог BLEU против разметки MQM и каппа разметчиков (к заданию 8).

Про профессию

Когда заказчик говорит «поднимем BLEU до 0,6», ваша работа — спросить, какие ошибки при этом останутся.

Формальные проверки дешёвы, объяснимы и попадают в договор. Метрики — нет.