ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Машинный перевод и оценка качества

Лабораторная работа № 3: метрики, контекст и проверка ошибок

Цифровая лингвистика и локализация
Учебные примеры связаны с корпусом и лабораторными работами курса.

Цель работы

Сравнить машинный и эталонный перевод, исследовать реакцию метрик на ошибки и предложить порядок ручной проверки.

В корпусе есть оригинал `en`, эталон `ru_ref` и машинный перевод `ru_mt`. Эталон — один допустимый вариант, а не единственная правильная формулировка.

Что оценивают разные средства

Средство	Что сопоставляет	Для чего используют
BLEU и chrF	Перевод с эталоном	Измерение поверхностного сходства
Эмбеддинги	Векторные представления	Отбор семантически далёких сегментов
Формальные правила	Поля, числа, теги, длину	Поиск определённых нарушений
Ручная оценка	Оригинал, перевод и контекст	Проверка смысла и пригодности

Переводческий контекст

Одинаковые слова могут требовать разной формы в кнопке, заголовке и сообщении о результате.

«Сохранить изменения» подходит для команды. «Сохранение изменений» называет процесс. «Изменения сохранены» сообщает о завершении.

Оценку допустимости формулировки привязывают к функции строки. Одного лексического сходства для этого недостаточно.

BLEU: совпадения словесных n-грамм

BLEU использует доли совпавших словесных n-грамм и штраф за слишком короткую гипотезу. Число совпадений ограничивается их числом в эталоне.

Гипотеза — оцениваемый перевод. Замена слова может изменить сразу несколько n-грамм.

В лабораторной используется упрощённый сглаженный BLEU отдельного сегмента. Его нельзя напрямую сравнивать с корпусным BLEU из публикаций.

Формула учебного BLEU

$$p_n = \frac{m_n + 1}{t_n + 1}, \qquad \mathrm{BLEU} = \mathrm{BP} \exp\left(\frac{1}{k} \sum_{n=1}^{k} \ln p_n \right)$$

$$\mathrm{BP} = \begin{cases} 1, & c > r, \\ \exp(1 - r/c), & 0 < c \le r. \end{cases}$$

m_n — совпавшие n-граммы, t_n — все n-граммы гипотезы. c, r — длины в словах; $k \le 4$ — доступные порядки. Пустая гипотеза получает 0.

Ручной расчёт: потеря отрицания

Эталон: «Не удалось подключиться к серверу». Гипотеза: «Удалось подключиться к серверу».

Все n-граммы гипотезы встречаются в эталоне. Поэтому каждая сглаженная доля равна 1. Различаются только длины: 4 и 5 слов.

$$\text{BLEU} = e^{1-5/4} \approx 0{,}779$$

Смысл изменился на противоположный. Высокое поверхностное сходство не показывает тяжесть ошибки.

Ручной расчёт: номинализация

Эталон: «Сохранить изменения». Гипотеза: «Сохранение изменений».

Слова целиком не совпали. С учётом сглаживания доли для униграмм и биграмм равны 1/3 и 1/2. Длины одинаковы.

$$\text{BLEU} = \sqrt{\frac{1}{3} \cdot \frac{1}{2}} \approx 0{,}408$$

Значение зависит и от сглаживания. Допустимость номинализации нужно оценить по назначению строки.

chrF: символьные совпадения

chrF использует совпадения символьных n-грамм. Общие части словоформ дают частичное совпадение, которого нет при сравнении слов целиком.

Точность P — доля совпавших n-грамм среди n-грамм гипотезы. Полнота R — доля совпавших среди n-грамм эталона.

Здесь precision обозначает точность совпадений. Это не проверка правильности смысла и не accuracy классификатора.

Формула учебной chrF

$$F_{\beta,n} = \frac{(1+\beta^2)P_n R_n}{\beta^2 P_n + R_n}, \qquad \beta = 2$$

$$\mathrm{chrF}_{\text{учебн.}} = \frac{1}{k}\sum_{n=1}^{k} F_{\beta,n}, \qquad k \le 6$$

В ноутбуке текст предварительно нормализуется, пробелы сохраняются; F-мера вычисляется для каждого порядка, затем усредняется.

В исходной chrF сначала усредняют точность и полноту по порядкам. Учебные значения относятся к реализации ноутбука, а не к SacreBLEU.

Реакция на две правки

Правка	Учебный BLEU	Учебная chrF
Номинализация	0,408	0,602
Потеря частицы «не»	0,779	0,919

chrF учитывает общие части слов, но пропуск короткой частицы затрагивает небольшую долю символов. Ни одно число не заменяет проверку смысла.

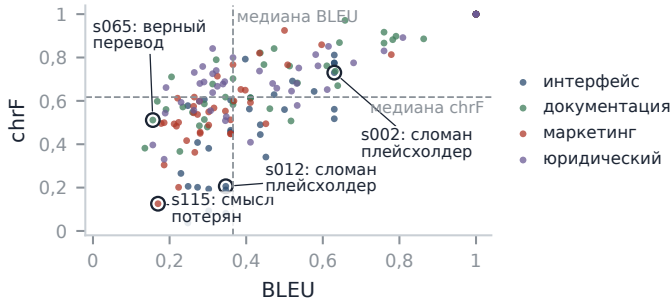
Шкала и способ усреднения

В работе метрики представлены на шкале 0–1. В других инструментах может использоваться шкала 0–100.

Среднее сегментных BLEU около 0,46 и среднее учебных chrF около 0,64 описывают этот корпус. Среднее сегментных BLEU не равно корпусному BLEU.

При сравнении систем фиксируют корпус, эталоны, токенизацию, сглаживание, версию реализации и способ агрегации.

Метрики на всех сегментах



Каждая точка — один перевод. В целом оценки согласуются, но отдельные сегменты требуют отдельного разбора.

Ранговая корреляция около 0,73 показывает согласованность ранжирования двух метрик, а не их соответствие качеству перевода.

Контролируемая ошибка: подстановочное поле

Эталон содержит `{name}`. Заменим его на `(name}`. Поле перестало соответствовать шаблону приложения.

В учебной реализации BLEU и chrF пунктуация удаляется до сравнения. Поэтому обе оценки могут остаться равными 1.

Причина здесь конкретна: предобработка скрыла различие. Сравнение исходных подстановочных полей обнаружит его до нормализации.

Контролируемая ошибка: отрицание

«Пароль должен содержать не менее 8 символов» и «Пароль должен содержать менее 8 символов» задают противоположные ограничения.

Изменение затрагивает одно короткое слово, поэтому значительная часть n-грамм остаётся прежней.

Проверка отрицания должна учитывать область действия: «не менее» нельзя приравнять к любому отрицательному слову в предложении.

Формальные проверки

Проверки сопоставляют наборы подстановочных полей и чисел, наличие тегов, длину сегмента и признаки возможного пропуска текста.

Правило указывает на риск определённого типа. Его срабатывание обычно требует проверки, а отсутствие срабатывания не доказывает правильность перевода.

Объём ручной проверки

Способ отбора	Помечено из 160	Доля корпуса
BLEU ниже медианы	78	48,8 %
chrF ниже медианы	80	50,0 %
Семантическое сходство < 0,7	15	9,4 %
Формальные проверки	8	5,0 %

Количество помеченных сегментов показывает нагрузку. Чтобы сравнить качество отбора, нужна разметка ошибок и подсчёт пропусков и ложных тревог.

Сегмент s002: пропущенная поломка

В машинном переводе поле {name} искажено до {имя}. BLEU около 0,630, семантическое сходство — 0,801.

Обе оценки выше выбранных порогов, а проверка подстановочных полей помечает сегмент.

Разные средства контроля дополняют друг друга. Высокое сходство не гарантирует техническую пригодность строки.

Ложная тревога: отрицание выражено иначе

Русское отрицательное значение может передаваться частицей, словом «невозможно», конструкцией «отсутствует» или иной формой.

Простая проверка наличия «не» ошибочно помечает s010 и s031. В задании нужно уточнить правило и сохранить срабатывание на s083, где потеряна часть содержания.

Лексические замены требуют контекста: «невозможно» не является универсальной заменой любой конструкции с «не».

Ручная оценка по учебной схеме MQM

Категория	Что проверяем
Передача смысла (Accuracy)	Пропуски, добавления, искажения оригинала
Нормы языка (Fluency)	Грамматику, орфографию, сочетаемость
Терминология	Соответствие понятия и термина глоссарию
Стиль	Регистр, тон и требования к типу текста
Техническая разметка	Сохранность полей и тегов

В учебной схеме веса серьёзности: 1, 5 и 25. Конкретные категории, веса и пороги задаются проектом; это не неизменные константы MQM.

Согласованность разметки

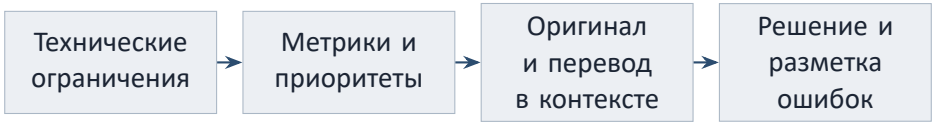
$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

p_o — наблюдаемая доля совпадений двух разметчиков; p_e — ожидаемая доля при независимом назначении меток с теми же частотами.

Если ответы совпали в 8 случаях из 10, а ожидаемое совпадение равно 0,22, каппа составляет около 0,744.

Десять сегментов — небольшой пример. Нужно также разобрать причины расхождений и уточнить инструкцию.

Порядок проверки перевода



Для выбранного порога оценивают пропуски и ложные тревоги на размеченных данных.

Подстройку правил выполняют на проверочной выборке. Итоговую оценку получают на независимых примерах.

Что включить в отчёт

Таблицу контролируемых правок с объяснением реакции метрик. Разбор технической поломки и корректного перефразирования.

Обоснование уточнённого правила отрицания, ложные тревоги и пропущенные ошибки. Вывод о применимости автоматического отбора.

Аргумент «chrF выше BLEU» недостаточен: шкалы и определения различаются. Нужны примеры, связанные с задачей.

→ **метрики и контролируемые ошибки** — параметры и результаты можно сравнить на примерах корпуса.

Источники

Papineni et al. (2002): BLEU.

Popović (2015): chrF.

MQM: терминология оценки качества перевода.

Числа на слайдах рассчитаны учебными функциями Л.р. № 3.