

ЛАБОРАТОРНАЯ РАБОТА № 4

Генерация текста

Чем «складно» отличается от «выучено наизусть»

Работа — демонстрация на одно занятие, а не расчётная. Её смысл в том, чтобы увидеть устройство языковой модели целиком и понять, почему сегодня так уже не делают.

Языковая модель — это одно распределение

Вся языковая модель, от посимвольной цепочки до GPT, делает ровно одно: по уже написанному тексту выдаёт **распределение вероятностей следующего элемента**.

Что видит модель

Контекст «Сохран» — и таблица по всем символам корпуса: «и» — 0,76, «е» — 0,12, «я» — 0,11, остальные почти ноль.

Что делает человек

Выбирает, как из этой таблицы достать один символ. Это отдельное решение, к обучению модели отношения не имеющее — и именно оно решает, каким получится текст.

Генерация — это цикл. Взять распределение, вытащить символ, дописать его к контексту, повторить. Больше в генерации текста ничего нет.

Почему в этом курсе модель посимвольная

Практические причины

Корпус курса — 160 сегментов, около 7 тысяч символов. Для модели по словам это ничтожно мало.

По символам алфавит маленький, данных хватает, и всё считается в браузере за секунды.

Содержательная причина

Посимвольная модель прозрачна насквозь: она предсказывает следующий символ по предыдущим n — и больше ничего.

Всё, что дальше будет сказано про большие модели, проверяется прямо на ней.

Сглаживание обязательно. Если сочетание символов не встретилось в обучении, его вероятность будет нулевой — и перплексия на любом новом тексте станет бесконечной. Сглаживание раздаёт невидённым продолжениям маленькую вероятность.

Температура: один параметр, три режима

$T < 1$

Распределение заостряется. При $T \rightarrow 0$ модель всегда берёт самый вероятный символ.

Текст предсказуемый, часто зацикливается.

$T = 1$

Распределение как есть. Символы берутся ровно с теми вероятностями, которые выучила модель.

$T > 1$

Распределение сглаживается, редкие символы получают шанс.

Текст разнообразнее и быстро перестаёт быть текстом.

Температура ничего не знает о смысле: она меняет форму распределения, и только. «Творческий» режим большой модели — тот же множитель на тех же числах.

→ **языковая модель и температура** — ползунок температуры и распределение следующего символа рядом.

top-k и top-p: обрезать хвост

Температура растягивает всё распределение целиком. Обычно хочется другого: выбросить заведомо негодные продолжения, не трогая остальные.

top-k

Оставить **k** самых вероятных символов, остальным дать ноль.

Число выживших фиксировано — и когда модель уверена, и когда нет.

top-p

Оставить столько символов, сколько нужно, чтобы их суммарная вероятность дошла до **p**.

Модель уверена — выживает один символ; сомневается — выживают десятки.

Порядок применения важен: сначала температура, потом обрезка. Иначе обрезка уберёт то, что температура только собиралась поднять.

Перплексия: чем её меряют

Перплексия — это «сколько вариантов модель в среднем перебирает на каждом символе».

Перплексия 2 — модель колеблется между двумя символами. Перплексия 30 — практически не знает, что будет дальше.

Меряется на тексте, **которого модель не видела**. На обучающем тексте она меряет память, а не язык.

Отсюда — разделение корпуса. Часть сегментов откладывается и в обучении не участвует. Всё, что говорится о качестве модели, говорится по отложенной части.

Это та же дисциплина, что кросс-валидация в работе № 1.

Кривая переобучения

Символьная модель на корпусе курса, порядок от 1 до 8

порядок	перплексия на обучении	на отложенном	списано дословно
1	13,37	16,14	0 %
2	5,81	11,09	0 %
3	2,70	10,36	7 %
4	1,80	11,67	66 %
5	1,51	13,37	84 %
6	1,42	14,90	100 %
8	1,39	17,13	100 %

На обучении перплексия падает всё время. На отложенном тексте у неё **минимум в середине** — на порядке 3. Дальше модель не учится языку, а запоминает корпус.

«Складно» и «выучено» — это разные вещи

Что модель выдаёт при разных порядках

порядок 1, списано 0 %

ереалитвеныевомачёть пстзUTТошетатм пмон / Прагранвыте ему

порядок 3, списано 7 % — лучший по перплексии

Времено / Очисляется поное влияются настро ном реждый делю.

порядок 6, списано 100 %

Временные файлы удаляются запрос должен в течение сохранен

На глаз лучший — третий текст. Он целиком составлен из кусков обучающего корпуса: ни одного своего сочетания символов. Модель, которая лучше всех обобщает, выглядит хуже той, которая просто помнит.

→ **языковая модель и температура** — списанные куски подсвечиваются прямо в сгенерированном тексте.

Почему это важно за пределами учебной модели

Механизм тот же

Большая модель отличается размером и архитектурой, но «правдоподобно» у неё точно так же не означает «верно» и не означает «ново».

Беглость текста — это свойство распределения, а не признак понимания.

Доля дословно списанного — это ровно та величина, вокруг которой идут все споры об авторском праве и больших моделях. Здесь её видно на корпусе в семь тысяч символов.

Что из этого следует в работе

Гладкий текст от языковой модели нельзя принимать как готовый перевод или готовую документацию.

Вопрос «не воспроизведён ли дословно чужой текст» — не теоретический: на этой модели он измеряется прямо.

Что делает ноутбук работы

Что там происходит

Посимвольная рекуррентная сеть обучается на текстах Шекспира — это учебник TensorFlow, встроенный в работу как есть.

Десять эпох, несколько минут на GPU в Colab. Перебора гиперпараметров нет намеренно.

Корпус там английский, и с корпусом курса результаты не сравнимы. Все числа этой лекции получены на русском корпусе курса символьной n -граммной моделью — её можно открыть в браузере и повторить.

Почему так, а не иначе

Посимвольная RNN — исторический этап, пройденный около 2015 года. Настраивать её до приемлемого качества бессмысленно: приемлемого качества у этой архитектуры нет.

Ценность в том, что её устройство целиком помещается в голову.

Что должно быть в отчёте

Обязательно

1. Что делает температура с распределением — своими словами, с примером текста при малой и большой.
2. Где находится минимум перплексии на отложенном тексте и почему он не там, где текст красивее.
3. Ответы на вопросы в конце ноутбука.

Не принимается

«Модель сгенерировала осмысленный текст».

Нужно сказать, на каком основании текст назван осмысленным, и проверить, не списан ли он. Для этого и нужна доля дословных совпадений.

Что унести из работы № 4

Про генерацию

Языковая модель выдаёт распределение. Всё остальное — температура, top-k, top-p — решения о том, как из него выбирать.

Качество текста на глаз и качество модели по перплексии — разные величины, и растут они в разные стороны.

→ **языковая модель и температура** — порядок, температура, перплексия и доля списанного — в браузере.

Про профессию

Беглый текст — слабейшее из возможных свидетельств качества. Проверять приходится то же, что и в работе № 3: фактическую точность, целостность, происхождение.