ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ

Генерация текста

Лабораторная работа № 4: вероятности, выбор продолжения и обобщение

Цифровая лингвистика и локализация
Учебные примеры связаны с корпусом и лабораторными работами курса.

Цель работы

Проследить, как языковая модель получает распределение следующего элемента и как из этого распределения строится текст.

Сопоставить связность результата, качество на отложенных данных и дословные совпадения с обучающим корпусом.

Авторегрессионная языковая модель

Авторегрессионная языковая модель оценивает вероятность следующего токена по предшествующему контексту. Токеном может быть символ, слово или часть слова.

$$P(x_1, \ldots, x_N) = \prod_{t=1}^{N} P(x_t \mid x_1, \ldots, x_{t-1})$$

Генерация последовательно выбирает токен, добавляет его к контексту и снова применяет модель.

Два учебных опыта

В браузере. Символьная n-граммная модель на русском корпусе курса.

Короткие контексты и вероятности доступны для непосредственного сравнения.

В ноутбуке. Рекуррентная сеть GRU на английском тексте Шекспира.

Можно проследить векторизацию, обучение и генерацию нейронной сети.

Корпуса, архитектуры и единицы разбиения различаются. Численные оценки двух опытов напрямую не сравнивают.

Символьная модель с конечным контекстом

В интерактивной модели параметр n задаёт число предыдущих символов, используемых как контекст. Вероятности оцениваются по частотам продолжений.

$$P(c \mid h) \approx \frac{\#(hc)}{\#(h)}$$

В литературе n-граммная модель часто означает контекст длиной n−1. Здесь следуем обозначению интерактивной страницы и указываем длину контекста явно.

Сглаживание

Если нужное продолжение не встретилось в обучении, частотная оценка даст ему вероятность 0. Один такой случай делает логарифмическую потерю бесконечной.

Сглаживание распределяет часть вероятности между невстречавшимися продолжениями. Интерполяция сочетает оценки по длинным и коротким контекстам.

Вероятность и выбор продолжения



Повторение цикла даёт последовательность символов. Одинаковая модель с разными способами выбора может порождать разные результаты.

Случайное зерно фиксируют для воспроизводимости. Для устойчивого вывода сравнивают несколько генераций.

Температура в формуле

$$p_T(i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}, \qquad T > 0$$

z_i — исходные оценки, или логиты. При $T < 1$ распределение становится более сосредоточенным; при $T > 1$ различия между вероятностями уменьшаются.

При T = 1 распределение не меняется. Температура изменяет выбор продолжения, но сама по себе не исправляет знания и ошибки модели.

Температура на простом распределении

Пусть исходные вероятности двух символов — 0,8 и 0,2. При $T = 0{,}5$ нормируем квадраты вероятностей:

$$\frac{(0{,}8^2,\ 0{,}2^2)}{0{,}8^2 + 0{,}2^2} \approx (0{,}941,\ 0{,}059)$$

Это иллюстративный расчёт. Более вероятный вариант стал ещё вероятнее, набор возможных символов сохранился.

Ограничение множества кандидатов

Top-k. Оставить k наиболее вероятных токенов. Остальным присвоить нулевую вероятность, оставшиеся вероятности нормировать.

Top-p. Упорядочить токены по вероятности и оставить минимальный начальный набор, суммарная вероятность которого не меньше p. Затем нормировать.

Число кандидатов при top-p зависит от формы распределения. Порядок применения температуры и фильтров фиксируют в описании опыта.

Перплексия

$$\mathrm{PP} = \exp\left(-\frac{1}{N}\sum_{t=1}^{N}\ln P(x_t \mid x_{<t})\right)$$

N — число токенов в проверочном тексте. Перплексия — экспонента средней логарифмической потери на правильных продолжениях. Меньшее значение означает более высокую вероятность проверочного текста.

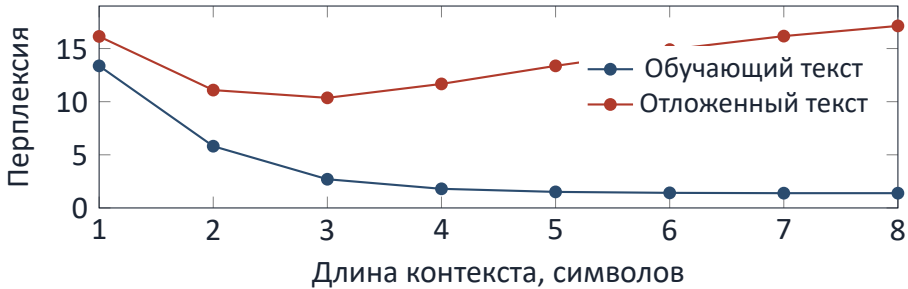
Значение 10 соответствует неопределённости выбора из 10 равновероятных вариантов. Реальное распределение не обязано быть равномерным.

Условия сравнения перплексии

Использовать один и тот же отложенный текст, токенизацию и способ нормирования. На символах и на подсловах одна и та же строка имеет разное число единиц.

При выборе порядка модели отложенная часть служит проверочной. Для независимой итоговой оценки нужна отдельная тестовая часть.

Длина контекста и переобучение



На отложенных 32 сегментах минимум — около 10,36 при контексте в 3 символа. Дальнейшее улучшение на обучении не переносится на новые сегменты.

Дословные совпадения с корпусом

Контекст	PP на отложенном	Доля совпадений
1 символ	16,14	0 %
3 символа	10,36	7 %
4 символа	11,67	66 %
6 символов	14,90	100 %
8 символов	17,13	100 %

Доля считается алгоритмом интерактивной страницы по найденным фрагментам обучающего текста. Это характеристика конкретной генерации и правила поиска совпадений.

Как оценивать сгенерированный текст

Раздельно проверить допустимость буквосочетаний, правильность словоформ, синтаксическую связность, передачу смысла и фактическую точность.

Проверить, не воспроизводит ли модель длинные фрагменты обучения. Само совпадение ещё не объясняет его причину.

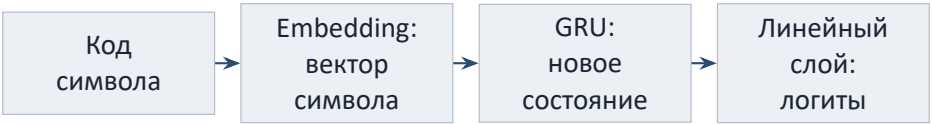
Результаты маленькой n-граммной модели иллюстрируют риск запоминания. Они не определяют величину этого риска для любой большой модели.

Обучающие пары в рекуррентной сети

Для строки «Привет» входом может быть «Приве», а правильными следующими символами — «ривет». На каждой позиции модель предсказывает символ со сдвигом на один.

Короткие последовательности объединяют в пакеты. Параметры сети обновляют по средней потере на правильных символах.

Архитектура из ноутбука



$$\mathbf{h}_t = \mathrm{GRU}(\mathbf{e}_t, \mathbf{h}_{t-1}), \qquad \mathbf{z}_t = W\mathbf{h}_t + \mathbf{b}$$

Предыдущее состояние передаётся в GRU вместе с текущим вектором. На выходе получаются оценки для всех символов словаря.

Что делает скрытое состояние

Скрытое состояние — вектор, который переносит информацию между шагами. Оно позволяет учитывать контекст за пределами одного символа.

Возможности памяти зависят от архитектуры, данных и обучения. GRU и LSTM помогают удерживать информацию, но не гарантируют правильную работу с дальними зависимостями.

Эпоха, пакет и шаг обучения

Пакет — группа примеров для вычисления потерь и обновления параметров. Шаг оптимизатора — одно такое обновление. Эпоха — проход по обучающему набору.

В ноутбуке выполняются 10 эпох. Время зависит от оборудования и среды; важнее наблюдать изменение потерь и примеров текста.

Что можно увидеть в выводе GRU

Модель может воспроизвести характерные буквосочетания, имена персонажей, переносы строк и оформление реплик.

По письменным символам корректнее говорить об орфографических закономерностях. Вывод о фонологической структуре потребовал бы других данных.

Связность и качество проверяют по результатам. Архитектура сама по себе не доказывает ни наличие, ни отсутствие осмысленных зависимостей.

Связь с более крупными моделями

Авторегрессионные трансформеры тоже предсказывают следующий токен. Архитектура, объём данных и способы обучения существенно расширяют их возможности.

Правдоподобие продолжения не гарантирует фактическую точность. Для перевода сохраняются требования к смыслу, терминологии и техническим ограничениям.

Что включить в отчёт

Показать несколько генераций с фиксированными параметрами и разными температурами. Объяснить изменение распределения.

Разобрать минимум перплексии, дословные совпадения и отличия n-граммной модели от GRU. Привести языковые примеры из вывода.

Характеристики «связный», «правильный» и «оригинальный» нужно обосновывать раздельно.

→ **языковая модель и выбор продолжения** — параметры и результаты можно сравнить на примерах корпуса.

Источники

TensorFlow: генерация текста с помощью символьной RNN.

Holtzman et al.: выбор продолжения по top-p.

Численные результаты n-граммной модели: интерактивная страница курса.
Нейросетевой опыт: Л.р. № 4.