ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ · ДОПОЛНИТЕЛЬНЫЕ БЛОКИ

Текст как данные

Представление языка, обучение моделей и оценка результатов

Направление «Цифровая лингвистика и локализация». Численные примеры на слайдах — из лабораторных работ курса, на том же корпусе из 160 сегментов локализации.

Содержание и связь с практикой

Блок	Основные понятия	Практика
1. Представление текста	Токены, словоформы, TF-IDF	Л.р. № 1
2. Обучение модели	Векторы, потери, градиент	Л.р. № 1 и № 2
3. Языковые модели	Контекст, перплексия, внимание	Л.р. № 4
4. Оценка перевода	BLEU, chrF, технические проверки	Л.р. № 3
5. Данные и разметка	Качество данных, MQM, согласие	Л.р. № 1 и № 3

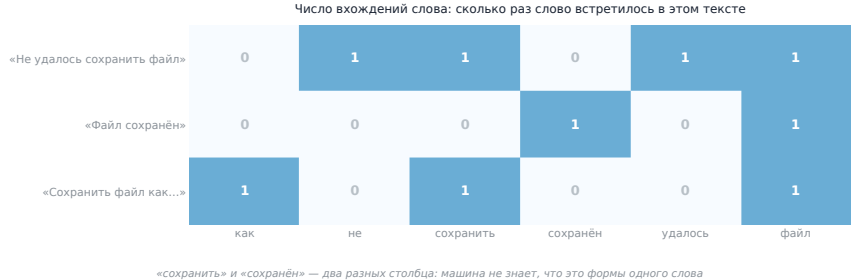
Каждый блок можно изучать отдельно. Определения сопровождаются формулами и примерами из корпуса курса.

БЛОК 1

Текст как данные

Представление текста определяет, какие языковые различия будут доступны модели. Рассмотрим единицы, нормализацию и признаки.

Векторизация текста



«сохранить» и «сохранён» — два разных столбца: машина не знает, что это формы одного слова

В рассматриваемых моделях строка матрицы соответствует сегменту, а столбец — признаку. Векторизация преобразует текст в числовое представление. Выбор единицы и нормализации определяет доступные модели различия.

Л.р. № 1, раздел 8. Один и тот же наивный Байес на одном и том же корпусе даёт от **0,381** до **0,631**. Меняется только способ превратить текст в признаки.

Токенизация и технические элементы

Токенизация — разбиение текста на единицы по заданным правилам.

Случай	Примеры	Решение зависит от задачи
Пунктуация	«серверу.» и «серверу»	Выделять ли точку отдельно?
Дефисы	«из-за», «интернет-магазин»	Сохранять ли целую единицу?
Технические элементы	`{name}`, `%s`, `<b>`	Как сохранить поле или тег?
Числа	«25 МБ», «02:00», «TLS 1.3»	Как учитывать формат?
Буква ё	«все» и «всё»	Значимо ли различие?

Векторизатор по умолчанию выделил из полей `{name}` и `{minutes}` слова name и minutes. Результат токенизации нужно проверять на исходных строках.

Нормализация словоформ

Стемминг сокращает словоформы по формальным правилам. Результат не обязательно совпадает с лингвистической основой.

сохранены, сохранить дают общий фрагмент сохран.

Лемматизация приводит словоформу к словарной форме. Неоднозначный разбор уточняют по контексту.

«Стали» может относиться к «стать» или «сталь».

В учебном опыте стемминг увеличил среднюю accuracy с 0,444 до 0,538; стандартное отклонение по разбиениям — 0,135. Причины проверяют по изменившимся предсказаниям.

Мешок слов и TF-IDF

Мешок слов — вектор частот слов из словаря. Порядок слов в нём теряется.

«Не удалось подключиться» и «Удалось не подключиться» дают одинаковые частоты.

TF-IDF учитывает частоту единицы в сегменте и её редкость по документам корпуса.

При сглаженном IDF из scikit-learn слово, встречающееся во всех документах, имеет IDF = 1, а не 0.

На одном разбиении словесный TF-IDF дал 0,400 против 0,425 у частот. Разница — один сегмент из сорока. Для сравнения нужны повторные разбиения.

TF-IDF по формуле

$$w(t, d) = \mathrm{tf}(t, d) \cdot \mathrm{idf}(t)$$

$$\mathrm{idf}(t) = \ln \frac{1 + N}{1 + \mathrm{df}(t)} + 1$$

tf — сколько раз слово t стоит в сегменте d;
df — в скольких сегментах оно есть;
$N = 160$ — сегментов в корпусе.

Затем вектор делят на его длину: так длинный и короткий сегменты становятся сравнимы.

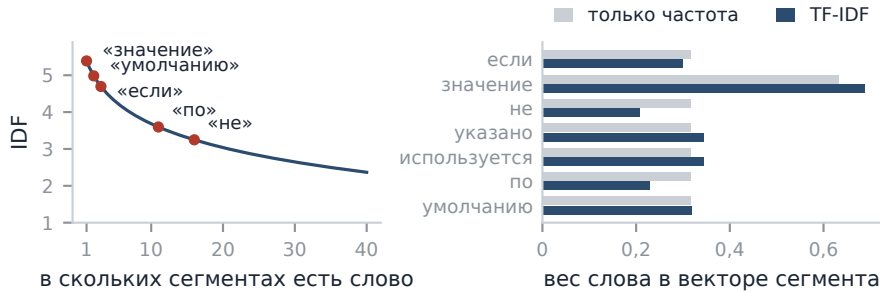
s044: «Если значение не указано, используется значение по умолчанию.»

слово	tf	df	idf	tf·idf	вес
значение	2	1	5,39	10,78	**0,689**
указано	1	1	5,39	5,39	0,345
используется	1	1	5,39	5,39	0,345
умолчанию	1	2	4,98	4,98	0,319
если	1	3	4,70	4,70	0,300
по	1	11	3,60	3,60	0,230
не	1	16	3,25	3,25	**0,208**

вес = tf·idf / 15,64, где
$15{,}64 = \sqrt{10{,}78^2 + 5{,}39^2 + \ldots + 3{,}25^2}$ — длина вектора

Вес TF-IDF не определяет переводческую важность: «не» весит втрое меньше «значения», хотя потеря отрицания может изменить смысл.

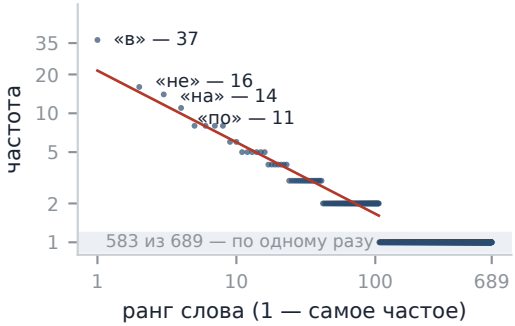
IDF и частота по документам



Слева — IDF при $N = 160$: слово из одного сегмента весит 5,39, из 16 — уже 3,25. Справа — s044: серым — веса по частоте, синим — с IDF. После нормирования относительный вес редких слов вырос, а «не» и «по» — снизился.

Признаков-слов в Л.р. № 1 — 679, а словоформ в корпусе 689: `TfidfVectorizer` по умолчанию отбрасывает словоформы из одного знака. Для русского это предлоги и союзы «в», «с», «к», «о», «у», «и», «а» — и три цифры.

Распределение частот и закон Ципфа



Частота слова примерно обратно пропорциональна его месту r в частотном списке:

$$f(r) \approx \frac{C}{r^a}$$

В логарифмическом масштабе ожидается наклон $-a$. В нашем небольшом корпусе $a \approx 0{,}55$.

Длинный хвост частот: **583** словоформы из 689 (85 %) встретились по разу.

Многие слова отсутствуют в обучающей части. Общие фрагменты помогают представить новые словоформы через знакомые n-граммы.

Символьные n-граммы

Символьные n-граммы: признак — подстрока из нескольких букв. Такие признаки не требуют лингвистического выделения морфем.

«сохранить» → сох, охр, хра, ран, ани, нит, ить
«сохранение» даёт те же сох, охр, хра, ран — родственные слова имеют общие признаки без словаря.

Тот же наивный Байес:

слова	0,444
стемминг	0,538
символьные 2–4	0,612
символьные 3–5	**0,631**

Цена: 5418–7821 признаков вместо 679, что усложняет интерпретацию отдельных вкладов.

Почему слова проигрывают на коротких строках. У 44 из 160 сегментов, когда они попадают в контрольную часть, нет ни одного слова, встречавшегося при обучении: вектор пустой. Пустых векторов из n-грамм нет ни одного.

→ **векторизация текста** — единица, стемминг, n-граммы и TF-IDF переключаются мышью.

БЛОК 2

Математический минимум

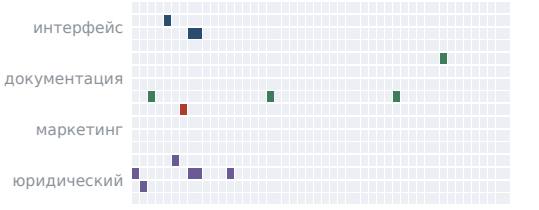
Пять понятий, на которых держится всё остальное: вектор, косинус, модель, потери, градиент. Каждая формула — с расшифровкой и с числами нашего корпуса.

Вектор и пространство признаков

Вектор размерности n — упорядоченный список из n чисел: $\mathbf{x} = (x_1, \ldots, x_n)$.

После векторизации сегмент — точка в пространстве признаков. Число координат равно числу признаков.

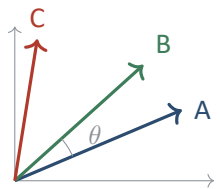
Близость точек зависит от признаков и выбранной меры.



Корпус глазами модели, фрагмент: 16 сегментов × 48 случайных n-грамм. Закрашено 14 клеток из 768.

Корпус Л.р. № 1 после символьных n-грамм 2–4 — **160** точек в **5418**-мерном пространстве. Ненулевых координат **2,1 %**: в среднем 115 на сегмент, у коротких строк интерфейса — 63.

Скалярное произведение и косинус



A и B смотрят почти в одну сторону, C — в другую.

Скалярное произведение — перемножить числа попарно и сложить. Для неотрицательных признаков общие большие координаты увеличивают результат:

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2 + \ldots + a_n b_n$$

Косинус — то же, делённое на длины векторов:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|}, \qquad \|\mathbf{a}\| = \sqrt{a_1^2 + \ldots + a_n^2}$$

Для TF-IDF он от 0 до 1: единица означает совпадение направлений, ноль — отсутствие общих ненулевых координат. Добавление слов может изменить направление.

Л.р. № 2, разделы 3–4: на 13 запросах к памяти переводов косинус и Левенштейн расходятся в 4 случаях, и в двух из них можно обосновать оба ответа.

→ **память переводов** — четыре меры похожести на одном запросе.

Косинус вручную

Признаки — слова, значение — сколько раз слово встретилось

A = «Не удалось подключиться к серверу», **B** = «…к базе данных»

	базе	данных	к	не	подключиться	серверу	удалось
A	0	0	1	1	1	1	1
B	1	1	1	1	1	0	1

$$\mathbf{A} \cdot \mathbf{B} = 0 \cdot 1 + 0 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 0 + 1 \cdot 1 = 4$$

$$\|\mathbf{A}\| = \sqrt{5}, \quad \|\mathbf{B}\| = \sqrt{6}, \qquad \cos(\mathbf{A}, \mathbf{B}) = \frac{4}{\sqrt{5} \cdot \sqrt{6}} = \frac{4}{\sqrt{30}} \approx 0{,}730$$

«Настройки поиска» и «Поиск по настройкам»: общих слов нет, и косинус по словам — ровно 0. По символьным n-граммам 2–4 общих 34 из 45 и 48, косинус — **0,731**. Близкая тематика без общих словоформ — то самое расхождение мер, которое разбирается в Л.р. № 2.

Обучение и обобщение

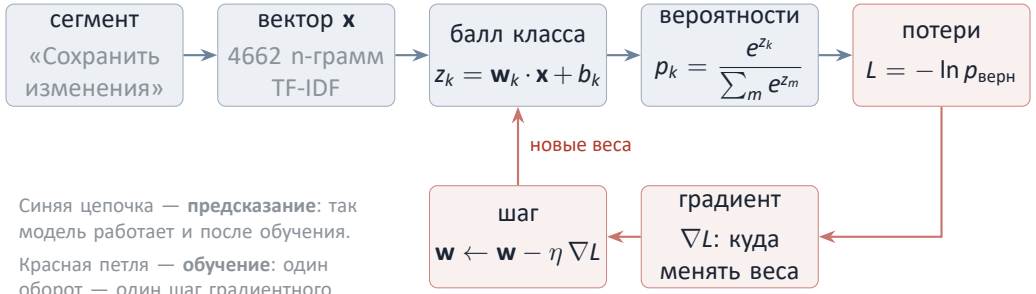
При обучении подбирают параметры модели по критерию ошибки на обучающих данных. Функция потерь численно задаёт этот критерий.

Обобщение — способность работать с новыми примерами. Её оценивают на данных, которые не использовались для обучения и выбора настроек.

В опыте Л.р. № 1 accuracy на обучающих данных равна 1,000, средняя при кросс-валидации — 0,744. Разрыв показывает различие условий оценки.

Обучение классификатора: весь цикл на одной схеме

Дальше каждый блок схемы — отдельный слайд, на корпусе Л.р. № 1



Синяя цепочка — **предсказание**: так модель работает и после обучения.

Красная петля — **обучение**: один оборот — один шаг градиентного спуска по всем 120 обучающим сегментам сразу.

В показанном опыте выполняются 3000 шагов оптимизации. Критерий остановки и результаты на отложенных данных проверяют отдельно. Весов, которые она подбирает, $4 \times 4662 = 18\,648$, и до первого шага все они равны нулю.

Модель: балл класса — взвешенная сумма n-грамм

$$z_k = \sum_{j=1}^{4662} w_{kj}\, x_j + b_k$$

x_j — TF-IDF n-граммы j в сегменте; у большинства — ноль.
w_{kj} — насколько n-грамма j говорит «за» класс k: плюс — за, минус — против.
b_k — сдвиг (свободный член): балл класса, когда признаков нет.

Это скалярное произведение: вектор сегмента на вектор весов класса.

Сколько тут чисел

У каждого из 4 классов свой вес для каждой из 4662 n-грамм:
$4 \times 4662 = 18\,648$ весов и 4 сдвига.
До обучения все они — нули.

Ответ модели — класс с наибольшим баллом. Учить её удобнее через вероятности — следующий слайд.

Пример. У отложенного сегмента «Компания оставляет за собой право…» 192 n-граммы. Их вклады в балл юридического класса в сумме дают 5,97, сдвиг — $-1{,}62$, итого $z = 4{,}35$.

Softmax: от баллов к вероятностям

$$p_k = \frac{e^{z_k}}{e^{z_1} + e^{z_2} + e^{z_3} + e^{z_4}}$$

Экспонента даёт положительные значения. Деление на их сумму нормирует распределение: вероятности в сумме равны 1. Порядок не меняется: больший балл — большая вероятность.

Отложенный сегмент после обучения: «Компания оставляет за собой право в любое время вносить изменения в настоящие Условия.»

класс	z_k	e^{z_k}	p_k
интерфейс	−1,62	0,20	0,003
документация	−0,69	0,50	0,006
маркетинг	−2,04	0,13	0,002
юридический	4,35	77,45	**0,989**
сумма		78,28	1

$p_{\text{юр}} = 77{,}45 / 78{,}28 = 0{,}989$

Зачем именно экспонента. Она усиливает разрывы: баллы юридического класса и документации различаются на 5,04, а вероятности — в $e^{5{,}04} \approx 155$ раз.

Вклады признаков в решение

Вклад n-граммы в оценку класса: $w_{kj}x_j$. На графике показаны семь наибольших вкладов.





Слева юридический сегмент определён верно: важны части «право» и «настоящие Условия». Справа «Согласие может быть отозвано…» ошибочно отнесено к маркетингу: сработали общие фрагменты с «можно» и «бесплатно».

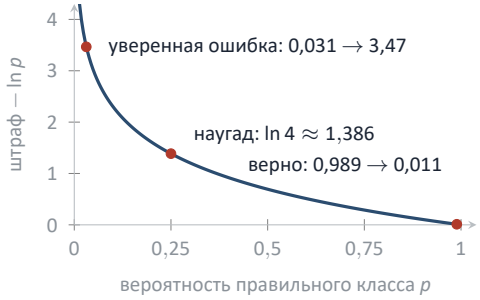
Функция потерь: перекрёстная энтропия

Берём вероятность, которую модель дала **правильному** классу; штраф за сегмент — её логарифм со знаком минус. Потери — средний штраф:

$$L = -\frac{1}{N}\sum_{i=1}^{N} \ln p_{y_i}(\mathbf{x}_i)$$

$N = 120$ обучающих сегментов, y_i — правильный класс i-го.

При $p = 1$ штраф ноль; чем меньше p, тем он больше — и без предела.



До обучения все веса — нули, каждому классу $p = \frac{1}{4}$, поэтому обучение стартует с $L = \ln 4 \approx 1{,}386$. Ошибка на «Согласие может быть отозвано…» стоит 3,47 — в 300 с лишним раз дороже верного ответа с $p = 0{,}989$.

Градиент и шаг оптимизации

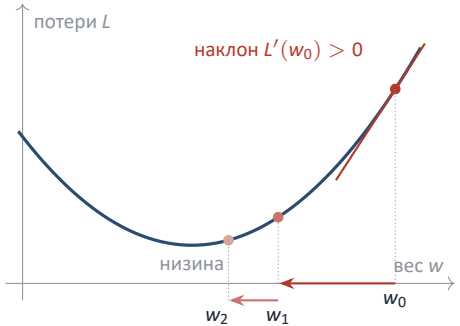
Градиент — вектор частных производных функции потерь по параметрам. Он указывает направление наибольшего локального роста потерь.

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla L(\mathbf{w})$$

η — скорость обучения. Знак минус задаёт движение против градиента. Большой шаг может вызвать колебания или расходимость; слишком маленький замедляет обучение.

SGD, Adam и RMSprop используют разные правила обновления параметров. Ни один выбор скорости не гарантирует одинакового результата для всех моделей.

Градиент на одном весе



Схема, а не данные: потери как функция одного веса.

Меняется только один вес w. Производная $L'(w)$ — наклон кривой потерь в текущей точке:

$$w_{\text{новый}} = w - \eta\, L'(w)$$

Наклон больше нуля — потери растут вправо, идём влево; меньше нуля — вправо.

Шаг пропорционален наклону: на склоне длинный, около минимума обычно короче. Поведение зависит от формы функции и выбранной скорости обучения.

Градиент ∇L — 18 648 таких наклонов сразу, по одному на вес.

Градиент нашей модели: ошибка × признак

Для логистической регрессии наклон по каждому весу считается одной формулой:

$$\frac{\partial L}{\partial w_{kj}} = \frac{1}{N}\sum_{i=1}^{N} \underbrace{\left(p_{ik} - [\,y_i = k\,]\right)}_{\text{ошибка в вероятности}} \cdot \underbrace{x_{ij}}_{\text{признак}}$$

$[y_i = k]$ — единица, если k — правильный класс i-го сегмента, иначе ноль. У правильного класса ошибка отрицательна (вероятность занижена), у остальных — положительна (завышена).

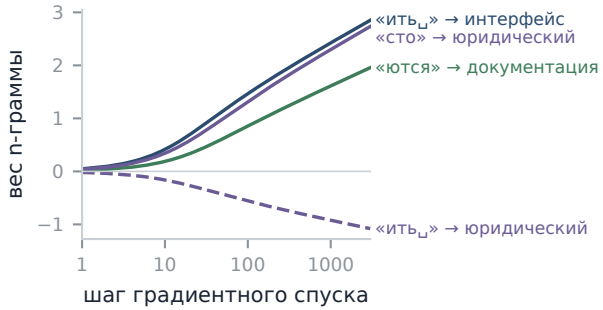
Что из формулы следует

Вес n-граммы меняют только сегменты, где она есть: при $x_{ij} = 0$ слагаемое — ноль. Вес растёт у класса, которому модель недодаёт вероятность, и падает у остальных.

Первый шаг на нашем корпусе

Все $p = \frac{1}{4}$. У каждой строки интерфейса с «ить␣» («Удалить…», «Отменить…») ошибка $\frac{1}{4} - 1 = -\frac{3}{4}$ у интерфейса и $+\frac{1}{4}$ у остальных классов. После шага вес «ить␣» для интерфейса — $+0{,}048$, для юридического — $-0{,}019$.

Изменение весов: признаки инфинитивов



Четыре веса из 18 648 за 3000 шагов.

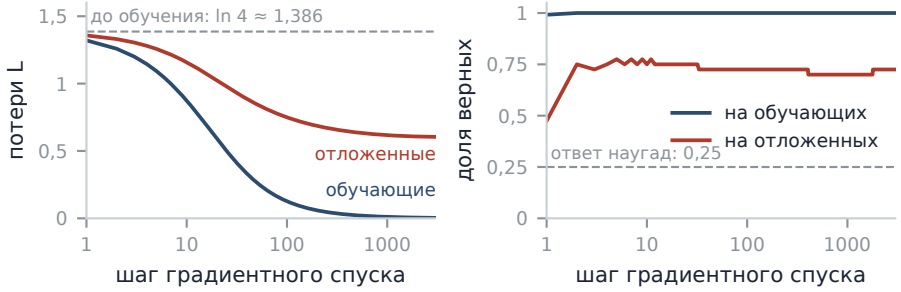
«ить␣» — конец инфинитива («удалить»). Для интерфейса вес вырос до 2,85, для юридического упал до −1,08.

«ются» («удаляются») — документация, 1,96; «сто» («стороны») — юридический, 2,73.

Модель не получала морфологическую разметку. Фрагмент «ить» связан с командами в обучающих примерах, поэтому его вес для интерфейса растёт.

Обучение на корпусе: потери и точность по шагам

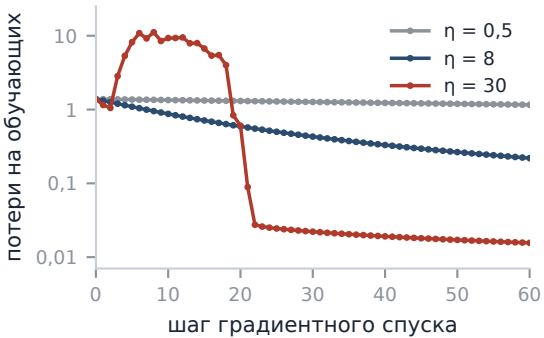
120 обучающих и 40 отложенных сегментов, $\eta = 8$, ось шагов логарифмическая



Старт — $\ln 4$. Ко 2-му шагу на обучающих верно всё, на отложенных — 0,750 (лучшее — 0,775, к концу — 0,725). Потери на обучающих уходят к нулю, на отложенных застревают на 0,605: разрыв показывает различие качества на обучающей и отложенной частях.

sklearn по умолчанию добавляет к L штраф за большие веса $\frac{\lambda}{2}\sum w^2$ (регуляризацию). С ним этот спуск приходит к весам `LogisticRegression` и даёт 0,750, как во «Введении».

Размер шага на нашем корпусе



η = 0,5: за 60 шагов потери 1,39 → 1,16 — медленно.

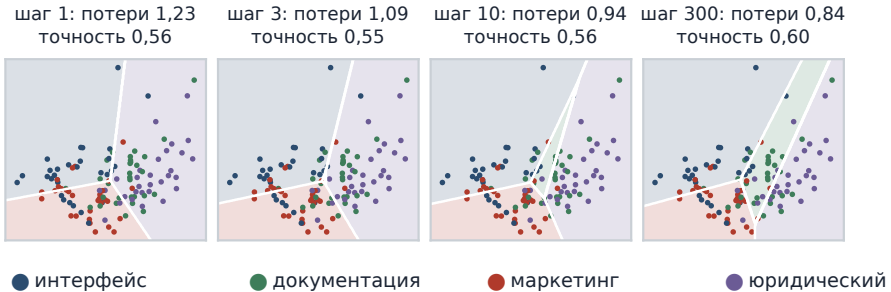
η = 8: потери ровно убывают, 0,22 к 60-му шагу.

η = 30: к 8-му шагу потери выросли до 11,15; к 20-му снизились. Более низкие обучающие потери ещё не означают лучшего обобщения.

Со штрафом за веса шаг 30 не даёт сходимости: через 3000 шагов потери 10,8, accuracy на отложенной части — 0,25.

Границы классов в двумерной проекции

Тот же спуск на двух признаках: n-граммы сжаты до двух координат LSA, как в Л.р. № 2

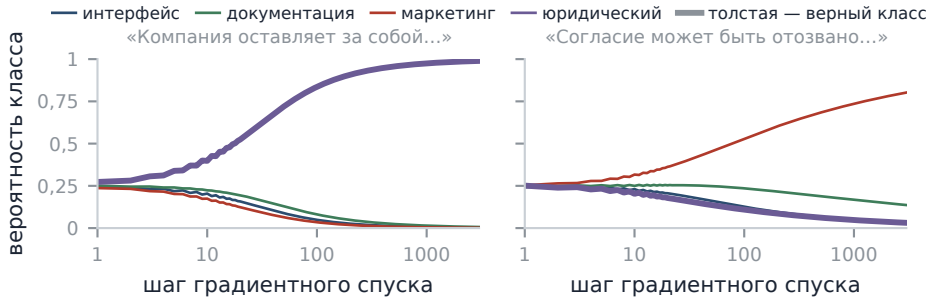


Точки — обучающие сегменты; фон — класс, который модель назовёт в этой точке; белые линии — границы. Область документации появляется только к 10-му шагу и растёт клином между интерфейсом и юридическими текстами.

Границы прямые, потому что модель линейная. На двух координатах точность 0,600 на обучающих и 0,625 на отложенных — против 0,725 на всех n-граммах: при сжатии часть различий потеряна.

Изменение предсказанных вероятностей

Вероятности четырёх классов для двух отложенных сегментов

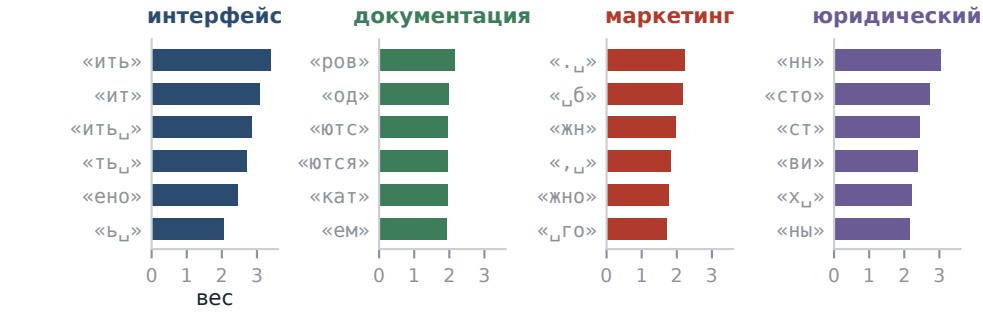


Слева: у юридического к 10-му шагу 0,398, к 3000-му — 0,989. Чем дольше обучение, тем увереннее верный ответ.

Справа: у неверно предсказанного класса вероятность также растёт — у маркетинга 0,802, у верного юридического 0,031.

Высокая вероятность не гарантирует правильного ответа: 0,8 у ошибки значит лишь, что n-граммы похожи на маркетинговые. Из 40 отложенных модель ошиблась на 11.

N-граммы с наибольшими весами



Шесть n-грамм с наибольшим весом для каждого класса после 3000 шагов. Знак ␣ — граница слова: «ить␣» — «ить» в конце слова.

Модель видела только сочетания букв и метки классов. Полученные связи можно сопоставить с грамматическими и лексическими признаками. Часть связей может отражать случайные особенности обучающей выборки.

Как прочесть эти веса лингвисту

Тип	N-граммы	Примеры слов	Возможная связь
Интерфейс	«ить», «ено»	удалить, найдено	команды и краткие причастия
Документация	«ются», «ров»	удаляются, параметров	возвратные формы и термины
Маркетинг	«␣б», «жно»	бесплатно, можно	выгода и модальность
Юридический	«сто», «х␣»	стороны, условиях	лексика договора и падежные формы

Это интерпретации связей на 120 обучающих сегментах. Их проверяют по контекстам и новым данным. Фрагмент слова не всегда является морфемой.

БЛОК 3

Языковые модели

От n-грамм до трансформера: что изменилось и почему это важно для вашей работы.

Авторегрессионная языковая модель

Авторегрессионная языковая модель оценивает вероятность следующего элемента по предыдущему контексту. Элементом может быть символ, слово или часть слова.

Повторное применение модели и выбор следующего элемента позволяют получить продолжение текста.

Предсказание продолжения может формировать полезные языковые представления. Однако высокая вероятность текста сама по себе не доказывает его фактическую точность.

Три подхода к языковому моделированию

Подход	Как учитывается контекст	Ограничение
N-граммная модель	Частоты в коротком фиксированном окне	Редкие контексты плохо представлены
Рекуррентная сеть	Скрытое состояние обновляется последовательно	Сложнее удерживать дальние зависимости
Трансформер	Внимание связывает доступные позиции	Ограниченный контекст и стоимость вычислений

Подходы продолжают использоваться в разных условиях. Это сравнение устройств моделей, а не строгая хронология их замены.

N-граммная модель в формулах

Вероятность текста раскладывается в цепочку: каждый символ — при условии всех предыдущих.

$$P(c_1 c_2 \ldots c_T) = P(c_1) \cdot P(c_2 \mid c_1) \cdot P(c_3 \mid c_1 c_2) \cdot \ldots \cdot P(c_T \mid c_1 \ldots c_{T-1})$$

В интерактивной модели параметр n задаёт число предыдущих символов, а вероятность оценивает частотами в обучающем тексте:

$$P(c_t \mid c_{t-n} \ldots c_{t-1}) \;\approx\; \frac{\#(c_{t-n} \ldots c_{t-1}\, c_t)}{\#(c_{t-n} \ldots c_{t-1})}$$

$\#(\ldots)$ — сколько раз цепочка встретилась. Обучение здесь — подсчёт, градиента нет.

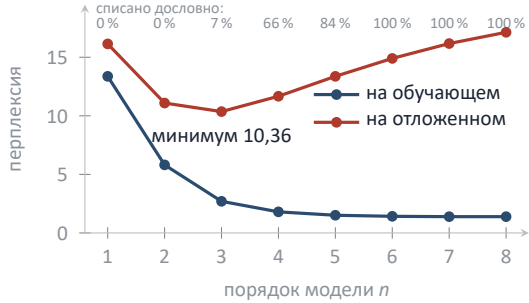
Пример, $n = 3$**.** В обучающем тексте после «сох» всегда шло «р»: «сохранены», «сохраняют», «сохранения». Модель ставит «р» с вероятностью **0,921** после сглаживания.

Сглаживание. Цепочка, которой не было, получила бы вероятность ноль. Поэтому оценку смешивают с более короткими контекстами; на интерактивной странице длинный контекст берётся с весом 0,7.

Перплексия: формула и кривая на нашем корпусе

$$\mathrm{PP} = 2^{-\frac{1}{T}\sum_{t=1}^{T} \log_2 P(c_t \mid \text{контекст})}$$

В показателе степени — средний штраф $-\log P$ за правильный символ, то есть перекрёстная энтропия из блока 2. $\mathrm{PP} = 10$: модель сомневается, как при выборе из 10 равновероятных символов.



На обучающем перплексия падает всё время. На отложенном — 32 сегментах из 160, которых модель не видела, — она минимальна при $n = 3$ и дальше растёт, а сгенерированный текст всё больше списан из корпуса. Та же картина, что у классификатора в блоке 2: качество на обучающих данных не заменяет оценку обобщения.

→ **языковая модель** — порядок и температура меняются ползунками.

Дальние зависимости и внимание

В рекуррентной сети информация передаётся через последовательность скрытых состояний. При самовнимании представление позиции напрямую зависит от других доступных позиций.

Это облегчает использование дальнего контекста, но не гарантирует правильного согласования или разрешения анафоры.

В авторегрессионном декодере маска закрывает будущие позиции. В двунаправленном кодировщике доступны обе стороны контекста.

Внимание: оценки связей и взвешенная сумма

Для каждой позиции вычисляются запрос $\mathbf{q}_i$, ключ $\mathbf{k}_i$ и значение $\mathbf{v}_i$.

$$a_{ij} = \mathrm{softmax}_j\left(\frac{\mathbf{q}_i \cdot \mathbf{k}_j}{\sqrt{d_k}}\right)$$

Представление позиции i — взвешенная сумма значений:

$$\mathbf{h}_i = \sum_j a_{ij}\mathbf{v}_j$$

Скалярное произведение даёт оценку связи запроса и ключа. Softmax нормирует оценки по доступным позициям j.

d_k — размерность ключа. Деление на $\sqrt{d_k}$ ограничивает масштаб оценок.

Запросы, ключи и значения — проекции входных векторов. Матрицы проекций подбираются при обучении.

Полное внимание использует матрицу оценок размера $n \times n$. Маска может закрывать часть позиций; в авторегрессионной модели закрыто будущее.

Предобучение и применение модели

Предобучение создаёт параметры и представления на большом наборе данных.

Дообучение продолжает обучение для выбранного домена или задачи.

В учебной работе используется готовый машинный перевод. Студент проверяет его на сегментах своего проекта, оценивает ошибки и ограничения.

В Л.р. № 3 использована модель `Helsinki-NLP/opus-mt-en-ru`. Длительность и стоимость обучения зависят от размера модели, данных и оборудования.

БЛОК 4

Метрики для текста

Как измеряют качество перевода, что при этом не измеряется и где метрика вводит в заблуждение.

Вариативность перевода

Один исходный текст может иметь несколько корректных переводов. Точное совпадение с единственным эталоном не охватывает эту вариативность.

Сравнение n-грамм даёт степень поверхностного сходства. Пригодность формулировки проверяют с учётом смысла, функции строки и требований проекта.

«Сохранить изменения» и «Сохранение изменений» лексически близки, но команда и название процесса подходят для разных мест интерфейса.

BLEU и словесные совпадения

Для $n = 1, 2, 3, 4$ берётся доля n-грамм гипотезы, нашедшихся в эталоне. Четыре доли усредняются **геометрически**, результат умножается на штраф за слишком короткий ответ. Смысла, грамматичности, синонимов и словоформ в этом определении нет.

эталон	гипотеза	BLEU
Не удалось подключиться к серверу	та же строка	1,000
Не удалось подключиться к серверу	**Удалось** подключиться к серверу	**0,779**
Сохранить изменения	Сохранение изменений	0,408

Противоположный смысл — 0,779, номинализация — 0,408. **BLEU считает форму, а не смысл.** Л.р. № 3, раздел 3.

BLEU по формуле

BLEU одного сегмента в том виде, в каком его считает Л.р. № 3

$$p_n = \frac{m_n + 1}{t_n + 1}, \qquad n = 1, 2, 3, 4$$

$$\text{BP} = \begin{cases} 1, & c > r, \\ e^{1 - r/c}, & c \le r \end{cases}$$

$$\text{BLEU} = \text{BP} \cdot \sqrt[k]{p_1 p_2 \cdots p_k}$$

t_n — сколько n-грамм слов в гипотезе; m_n — сколько из них есть в эталоне (каждая — не больше раз, чем там встречается).

c и r — длина гипотезы и эталона в словах. BP (brevity penalty) — штраф только за слишком короткий перевод.

k — сколько долей удалось посчитать: в гипотезе из двух слов нет ни 3-грамм, ни 4-грамм.

+1 в числителе и знаменателе — сглаживание. Без него одна нулевая доля обнуляет весь BLEU: произведение с нулём — ноль. Слова сравниваются в нижнем регистре, пунктуация отбрасывается.

BLEU вручную: откуда 0,779 и 0,408

«Удалось подключиться к серверу»
эталон: «Не удалось подключиться к серверу»

n	совпало, m_n/t_n	p_n
1	4 из 4	$5/5 = 1$
2	3 из 3	$4/4 = 1$
3	2 из 2	$3/3 = 1$
4	1 из 1	$2/2 = 1$

Среднее долей — 1. Но $c = 4$, $r = 5$:
$\mathrm{BP} = e^{1-5/4} = e^{-0{,}25} = \mathbf{0{,}779}$.

«Сохранение изменений»
эталон: «Сохранить изменения»

n	совпало, m_n/t_n	p_n
1	0 из 2	$1/3$
2	0 из 1	$1/2$
3, 4	в гипотезе таких нет	

$c = r = 2$, $\mathrm{BP} = 1$:
$\mathrm{BLEU} = \sqrt{\frac{1}{3} \cdot \frac{1}{2}} = \sqrt{\frac{1}{6}} = \mathbf{0{,}408}$.

Слева совпали все n-граммы, и весь штраф — за длину: потерю «не» BLEU видит только как недостающее слово. Справа не совпало ни одного слова, а BLEU всё равно 0,408 — это сглаживание, а не сходство.

chrF: совпадения частей слов

chrF сравнивает символьные n-граммы и считает F-меру — точность вместе с полнотой. У «сохранить» и «сохранение» общая часть, и разные словоформы могут получить частичное совпадение.

	BLEU	chrF
номинализация	0,408	0,602
потеряно отрицание	0,779	**0,919**

Символьное сходство имеет ограничения. Потерянное отрицание chrF замечает ещё хуже BLEU: пропала одна короткая частица.

Ещё две метрики, о которых стоит знать: TER — нормированное число редакционных операций до эталона; COMET — нейросеть, обученная на человеческих оценках.

→ **метрики машинного перевода** — BLEU и chrF одного сегмента, с учётом морфологии и без.

chrF по формуле: точность, полнота, F-мера

Для порядков $n = 1, \ldots, 6$ считаем совпадения m_n:

$$P_n = \frac{m_n}{\text{в гипотезе}}, \qquad R_n = \frac{m_n}{\text{в эталоне}}$$

$$F_n = \frac{(1+\beta^2)\, P_n R_n}{\beta^2 P_n + R_n}, \quad \beta = 2$$

$$\text{chrF} = \tfrac{1}{6}\,(F_1 + \ldots + F_6)$$

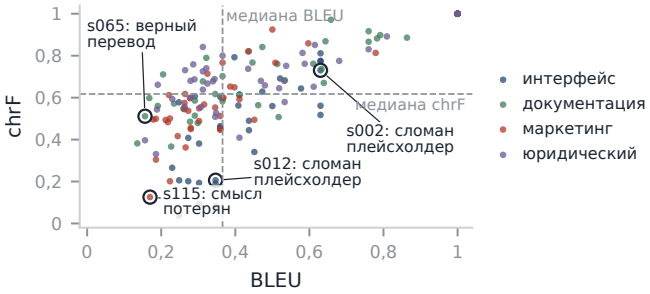
P_n и R_n — доли совпадений в гипотезе и эталоне. $\beta^2 = 4$ усиливает влияние полноты. Это учебная реализация.

«Сохранение изменений» против эталона «Сохранить изменения»

n	m_n	P_n	R_n	F_n
1	16	16/20	16/19	0,833
2	14	14/19	14/18	0,769
3	11	11/18	11/17	0,640
4	9	9/17	9/16	0,556
5	7	7/16	7/15	0,461
6	5	5/15	5/14	0,352
среднее — chrF				**0,602**

С потерянным «не» точность у chrF равна 1 на всех n, а полнота — около 0,9: недостаёт трёх символов «не␣» из 33. Итог 0,919 — метрика почти не заметила отрицания.

BLEU и chrF на всём корпусе



Точка — сегмент машинного перевода Л.р. № 3. В целом метрики согласны: ранговая корреляция **0,73**.

s002 с поломкой поля выше обеих медиан. Допустимый s065 — ниже обеих.

Медианы — 0,366 и 0,617. Порог по любой отсекает половину корпуса, не отличая сломанное от перефразированного.

Ошибки с высоким сходством

что случилось	пример из Л.р. № 3	BLEU
поле повреждено	s002: `Удалить файл "(имя}"?` — поле не соответствует шаблону	0,630
потеряно отрицание	«Удалось подключиться» вместо «Не удалось»	0,779
верный перевод	s065: «Приведенный ниже пример показывает…» вместо «В следующем примере показана…»	0,156

Медиана BLEU по корпусу — **0,366**. Приёмка по ней пропустила бы сломанную строку и отклонила допустимое перефразирование. Причина одна: метрики сравнивают форму, и не имеют отдельной проверки смыслового противоречия. Небольшая правка может сильно изменить смысл при высоком сходстве.

Метрики и формальные проверки

Средство отбора	Помечено из 160	Доля
BLEU ниже медианы	78	48,8 %
chrF ниже медианы	80	50,0 %
Семантическое сходство < 0,7	15	9,4 %
Формальные проверки	8	5,0 %

Нагрузка на редактора — только одна сторона сравнения. Нужно также определить пропуски и ложные тревоги. Проверки не гарантируют обнаружения всех ошибок.

Условия применения метрик

Системы сравнивают на одинаковом корпусе, с теми же эталонами и реализацией метрики. Проверяют результаты по типам контента и примеры существенных ошибок.

Учебный BLEU считается для отдельных сегментов со сглаживанием. Учебная chrF усредняет F-меры по порядкам n-грамм. Эти реализации отличаются от стандартных корпусных инструментов.

Порог сходства помогает расставить приоритеты просмотра, но пригодность отдельного перевода требует проверки смысла и технических условий.

БЛОК 5

Данные и разметка

Сравнение изменений модели и данных, сколько стоит разметка и насколько ей можно верить. Это та часть работы, которую делает лингвист.

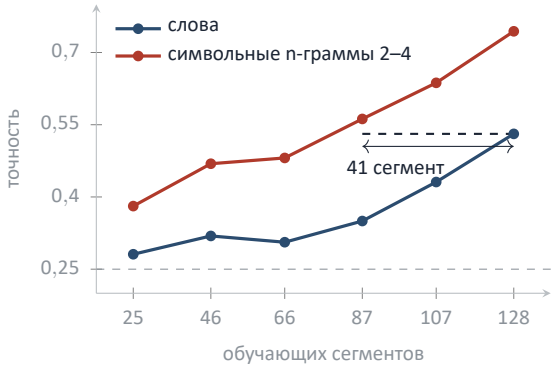
Сравнение изменений модели и данных

Пять изменений и что они дают (Л.р. № 1, разделы 8, 9 и 13):

изменение	результат	наблюдение
подобрать гиперпараметры, 48 комбинаций	+0,000	исходная настройка — лучшая
объединить слова и n-граммы	−0,019	в этом опыте качество ниже
сменить модель	0,550–0,744	диапазон 0,19
сменить предобработку	0,381–0,631	диапазон 0,25
разметить больше, 20 Newsgroups	**0,546 → 0,830**	в 11 раз больше примеров

Вывод для этого опыта: нужно проверить данные, признаки и модель. Опыт на 20 Newsgroups использует другой корпус; его прирост нельзя напрямую сравнивать с приростами на 160 сегментах.

Качество и объём обучающей выборки



Логистическая регрессия, пятикратная кросс-валидация.

Символьные n-граммы на **87** сегментах уже обгоняют слова, обученные на всех **128**. Удачная идея о признаках экономит 41 сегмент разметки.

Обе кривые на правом краю ещё растут: дополнительные размеченные данные могут помочь. Это гипотеза, которую проверяют новым опытом.

→ **данные и разметка** — кривые считаются в браузере, модель переключается.

MQM: учебная схема ручной оценки

Категория	Что проверяем	Пример нарушения
Передача смысла	Соответствие оригиналу	Пропущена инструкция
Нормы языка	Грамматика, сочетаемость	Ошибка согласования
Терминология	Соответствие глоссарию	Неверный термин
Стиль	Регистр и тон	«Ты» вместо «вы»
Технические поля	Сохранность полей и тегов	Искажено `{name}`

Веса в Л.р. № 3: критическая ошибка — 25, серьёзная — 5, незначительная — 1. Категории и веса согласуют с требованиями проекта.

Метрика против разметки

Десять сегментов, размеченных в разделе 6 Л.р. № 3

сегмент	ошибка	BLEU
s002	критическая, разметка	0,630
s006	незначительная, термин	0,630
s012	критическая, разметка	0,347
s115	критическая, точность	0,170
s065	**нет**	0,156

Пять из десяти; остальные — на интерактивной странице.

Критическая и незначительная ошибки получили *одинаковый* BLEU. Безупречный перевод — самый низкий из десяти.

Ранговая корреляция BLEU и штрафа MQM — $+0{,}18$: на этой маленькой выборке заметной связи не видно. Порога BLEU, при котором приёмка на этих десяти сегментах не ошибается, не существует.

→ **данные и разметка** — порог приёмки двигается ползунком, ошибки считаются сразу.

Согласие разметчиков

Разметка — это измерение, и у измерения есть надёжность. Если два человека размечают один материал по-разному, ненадёжна и разметка, и всё, что из неё выведено.

Каппа Коэна — согласие с поправкой на ожидаемые случайные совпадения:

$$\kappa = \frac{p_{\text{совп}} - p_{\text{случ}}}{1 - p_{\text{случ}}}$$

Пример Л.р. № 3: совпали 8 ответов из 10, случайно совпало бы 22 %: $\kappa = \frac{0{,}80 - 0{,}22}{1 - 0{,}22} \approx 0{,}744$ — значение для учебного примера.

Зачем вычитать случайные совпадения. Если 80 % сегментов без ошибок, два разметчика, независимо назначающих метки с такими частотами, совпадут в **65 %** случаев — просто потому, что оба чаще ставят «нет». Каппа у них — ноль.

Расхождения примера — s003: точность или терминология? s006: терминология или стиль? Оба ответа можно обосновать, пока руководство для разметчиков не решило иначе. Написать его — профессиональная задача (Л.р. № 3, задание 8).

Происхождение и состав данных

Права на корпус

Тексты из интернета не становятся свободными оттого, что доступны. У OPUS, Universal Dependencies и подобных ресурсов лицензии указаны явно — их надо читать.

Персональные данные

Переписка, тикеты поддержки и отзывы содержат имена, адреса, номера. Условия использования и порядок обработки таких данных определяют до подготовки корпуса.

Следы машинного перевода

В параллельном корпусе могут оказаться автоматически переведённые или повторяющиеся тексты. Они могут переносить ошибки и нарушать независимость оценки.

Умение сказать заказчику, что с корпусом что-то не так, — часть профессии, и её не заменит никакая метрика.

Связь представления, обучения и оценки

Выбор единиц текста определяет признаки. Признаки и обучающие примеры влияют на модель. Критерий оценки показывает только выбранную сторону качества.

Лингвистический анализ помогает определить категории, подготовить инструкцию по разметке и объяснить ошибки по контексту.

Для каждой задачи нужно согласовать, что считается правильным ответом, как его измеряют и какие ошибки остаются вне автоматической проверки.

Источники и обозначения

scikit-learn: TF-IDF, классификация и оценка моделей.

Vaswani et al.: механизм внимания. Papineni et al.: BLEU. Popović: chrF.

Числа приведены для корпуса и реализаций курса. Учебные BLEU и chrF отличаются от стандартных корпусных реализаций.