

Текст как данные

Как язык попадает в машинное обучение и что с ним там происходит

Магистратура «Цифровая лингвистика и локализация». Все числа на слайдах — из лабораторных работ курса, на том же корпусе из 160 сегментов локализации.

Пять блоков и где их потрогать руками

Основной курс объясняет машинное обучение на числах. Эти блоки — о том, как в эту схему попадает текст. Каждый привязан к лабораторной и к странице, где то же самое можно покрутить руками.

блок	о чём	работа	playground
1	текст как данные: токены, словоформы, признаки	Л.р. № 1	векторизация
2	математический минимум: вектор, косинус, градиент	Л.р. № 2	память переводов
3	языковые модели	Л.р. № 4	языковая модель
4	метрики для текста	Л.р. № 3	метрики перевода
5	данные и разметка	Л.р. № 1 и № 3	данные и разметка

Все playground'ы — на konkin-nikita.ru/gd_learn: они считают те же числа на том же корпусе, что и ноутбуки.

БЛОК 1

Текст как данные

Модель видит числа. Всё, что вы знаете о языке, попадает в неё ровно одним способом — через то, как вы превратили текст в числа.

Модель не читает текст

Число вхождений слова: сколько раз слово встретилось в этом тексте

«Не удалось сохранить файл»	0	1	1	0	1	1
«Файл сохранён»	0	0	0	1	0	1
«Сохранить файл как...»	1	0	1	0	0	1
	как	не	сохранить	сохранён	удалось	файл

«сохранить» и «сохранён» — два разных столбца: машина не знает, что это формы одного слова

Любой алгоритм принимает таблицу: строка — объект, столбец — признак. Между текстом и моделью всегда стоит шаг векторизации, и проектирует его человек: выбор единицы, нормализация, отбор признаков — всё это решения о языке.

Л.р. № 1, раздел 8. Один и тот же наивный Байес на одном и том же корпусе даёт от **0,381** до **0,631**. Меняется только способ превратить текст в признаки.

Шаг первый: токенизация

Разбить текст на единицы. Кажется тривиальным — до первого реального файла.

Пунктуация: «серверу.» и «серверу» — одна единица или две?

Дефисы: «из-за», «кто-нибудь», «интернет-магазин».

Плейсхолдеры: {name}, %s, — их нельзя ни резать, ни переводить.

Числа и единицы: «25 МБ», «02:00», «TLS 1.3».

Буква ё: «все» и «всё» — разные слова.

Готовые токенизаторы: `razdel`, `nltk`, `spaCy`. Регулярное выражение годится для учебной задачи и ломается на реальной.

Л.р. № 1, раздел 4. Словарь корпуса начинается с 00, 02, 25, 429, api, csv, https, minutes, name. Токенизатор по умолчанию разрезал время и превратил плейсхолдеры {minutes} и {name} в английские слова.

Шаг второй: нормализация словоформ

Стемминг

Усечение до основы по правилам.
Быстро, грубо, без словаря; основа не обязана быть словом.

сохранены, сохранить → сохран
изменения → изменен

— вывод раздела 8 Л.р. № 1

Для английского разница невелика. Для русского принципиальна: одна лексема даёт десятки словоформ, и без нормализации модель считает их не связанными между собой признаками.

Л.р. № 1: стемминг поднимает наивный Байес с 0,444 до 0,538 — но разброс между долями доходит до 0,135. Одна таблица этого не доказывает; доказывают сегменты, которые он исправил.

Лемматизация

Приведение к словарной форме.
Нужны словарь и снятие омонимии:
«стали» — это «стать» или «сталь»?

Для русского: morphology3, spaCy,
Natasha.

Шаг третий: мешок слов и TF-IDF

Мешок слов

Словарь корпуса и число вхождений каждого слова. Порядок теряется полностью: «не удалось подключиться» и «удалось не подключиться» — один и тот же вектор.

TF-IDF

Вес слова — произведение двух множителей: как часто оно в этом тексте (TF) и насколько редко по корпусу (IDF). То, что есть везде, весит почти ноль.

TF-IDF — не «улучшенный мешок слов», а другой ответ на вопрос, что считать важным. В разделе 6 Л.р. № 1 на одном разбиении он даже проигрывает: 0,400 против 0,425. Это один сегмент из сорока — то есть ничего, и ровно поэтому дальше в работе одна пятая корпуса по очереди становится контрольной.

Шаг четвёртый: а нужно ли слово вообще

Символьные n-граммы: признак — подстрока из нескольких букв. Понятия «слово» в модели нет.

«сохранить» → сох, охр, хра, ран, ани, нит, ить

«сохранение» даёт те же сох, охр, хра, ран — словоформы похожи без словаря и без правил.

Тот же наивный Байес:

слова 0,444

стемминг 0,538

символьные 2–4 0,612

символьные 3–5 **0,631**

Цена: 5418–7821 признаков вместо 679, и прочесть их человек не может.

Почему слова проигрывают на коротких строках. У 44 из 160 сегментов на контроле нет ни одного слова, встречавшегося при обучении: вектор пустой. Пустых векторов из n-грамм нет ни одного.

→ **векторизация текста** — единица, стемминг, n-граммы и TF-IDF переключаются мышью.

БЛОК 2

Математический минимум

Четыре понятия, которых достаточно, чтобы понимать всё остальное в курсе. Без вывода формул.

Вектор — это просто список чисел

Вектор длины n — упорядоченный список из n чисел. И всё.


После векторизации каждый сегмент — точка в пространстве, где измерений столько, сколько признаков.

Представить 5418 измерений нельзя, и не нужно: всё, что мы делаем с векторами, определено одинаково для любого их числа.

Похожие тексты — близкие точки. Вся работа с векторными представлениями держится на этой фразе.

Корпус Л.р. № 1 после символьных n -грамм 2–4 — это **160** точек в **5418**-мерном пространстве. У большинства координат значение ноль: в коротком сегменте встречается лишь малая доля всех n -грамм корпуса.

Скалярное произведение и косинус



А и В смотрят почти в одну сторону, С — в другую.

Скалярное произведение: перемножить числа попарно и сложить. Велико, если оба вектора велики в одних и тех же местах.

Косинус — то же, делённое на длины векторов. Для признаков TF-IDF он лежит между 0 и 1: единица — одинаковый состав, ноль — ни одного общего признака.

Длина текста больше не влияет — в отличие от расстояния Левенштейна.

Л.р. № 2, разделы 3–4: на 13 запросах к памяти переводов косинус и Левенштейн расходятся в 4 случаях, и в двух из них защитимы оба ответа.

→ **память переводов** — четыре меры похожести на одном запросе.

Что значит «обучить модель»

У модели есть **веса** — числа, которые она может менять.

Есть **функция потерь** — число, показывающее, насколько предсказания расходятся с правильными ответами.

Обучение — подобрать веса так, чтобы потери стали меньше. Никакого понимания в этом нет: модель не «выучила язык», она подобрала числа.

Модель воспроизводит то, что было в обучающих данных, — вместе с их ошибками и перекосами. К этому мы вернёмся в блоке 5.

Отсюда главное правило: модель проверяют на данных, которых она не видела.

В Л.р. № 1 (раздел 12) лучшая модель на своих обучающих сегментах даёт **1,000**, на отложенных — **0,744**. Первое число измеряет память, второе — способность обобщать.

Градиент: как именно подбирают веса

Перебрать все комбинации весов невозможно. **Градиент** отвечает на вопрос: если чуть-чуть изменить каждый вес, в какую сторону потери убывают быстрее всего? Дальше — шаг в эту сторону, пересчёт, снова шаг. Это градиентный спуск: спуск по склону в тумане, на ощупь.

Размер шага

Слишком велик — модель перескакивает низину и расходится.
Слишком мал — обучение не заканчивается. SGD, Adam, RMSprop — разные способы выбирать шаг.

→ **градиентный спуск** — шаги видны на поверхности потерь; расходимость ловится на лету.

Что из этого следует

Обучение — итеративный подбор, поэтому результат зависит от начальной точки и от случайности.
Знать формулу градиента не нужно; понимать это — нужно.

БЛОК 3

Языковые модели

От n-грамм до трансформера: что изменилось и почему это важно для вашей работы.

Задача языковой модели не менялась с 1950-х

Предсказать следующую единицу по предыдущим. Единицей может быть символ, слово или часть слова; на выходе — распределение вероятностей по всему словарю.

Из этой задачи вырастает всё остальное: генерация, подсказки ввода, перевод, ответы на вопросы.

Как из распределения выбирают символ — температура, top-k, top-p — разобрано в лекции к Л.р. № 4.

→ **языковая модель и температура** — распределение следующего символа видно целиком.

В постановке нет ничего про смысл. Модель оптимизирует правдоподобие продолжения, а не истинность, уместность или пользу. Всё, что выглядит как понимание, — следствие статистики на очень больших объёмах текста.

Три поколения

N-граммы

до ~2010

Таблица частот: какие единицы за какими шли. Просто и быстро; контекст — несколько единиц, дальше данных не хватает.

Рекуррентные сети

2010–2017

Состояние передаётся по цепочке. Контекст в принципе не ограничен, на практике затухает; обучать можно только последовательно.

Трансформеры

с 2017

Внимание: каждая позиция напрямую видит все остальные. Дальний контекст не теряется, обучение параллельно — отсюда огромные модели.

Предел первого поколения видно на нашем корпусе. Символьная n -граммная модель при $n = 1$ пишет оригинальную бессмыслицу, при $n = 8$ — гладкий текст, на 100 % списанный из корпуса. Перплексия на отложенных текстах минимальна при $n = 3$. «Складно» и «выучено наизусть» — одна ось.

Что дало внимание

В рекуррентной сети, чтобы связать слово с тем, что было двадцать слов назад, информация проходит двадцать шагов и на каждом частично теряется. Внимание убирает цепочку: каждая позиция сразу получает доступ ко всем остальным и сама решает, на какие смотреть.

Что стало возможно

Согласование на большом расстоянии перестаёт быть проблемой;
разрешение анафоры становится в принципе достижимым.

Чем за это платят

Вычисления растут квадратично от длины текста: вдвое более длинный документ стоит вчетверо дороже.

Для лингвиста главное вот что: модель научилась учитывать структуру предложения, не имея никакого её описания. Синтаксис в неё не закладывали.

Почему модели берут готовыми

Предобучение

Месяцы вычислений на миллиардах слов. Вам недоступно — и не нужно.

Дообучение

Часы на вашей задаче и вашей тысяче примеров.

Вывод для локализации: свою модель перевода вы обучать не будете. Вы будете брать готовую, оценивать её на своих данных и решать, годится ли она.

Это не упрощение курса, а описание реальной работы. Поэтому центральная лабораторная — не про обучение, а про оценку.

Л.р. № 3 работает ровно по этой схеме. Машинный перевод корпуса сделан готовой моделью Helsinki-NLP/opus-mt-en-ru (раздел 10 работы); студент ничего не обучает, он измеряет.

БЛОК 4

Метрики для текста

Как измеряют качество перевода, что при этом не измеряется и где метрика вводит в заблуждение.

Почему ассигурацию здесь не работает

В классификации ответ либо совпал с правильным, либо нет. Для перевода так нельзя: «Сохранить изменения» и «Сохранение изменений» допустимы оба, а точное совпадение строк дало бы ноль за верный перевод.

Значит, нужна метрика *степени* совпадения с эталоном.

Главное ограничение всего подхода: эталон один, а верных переводов много. Всё, что метрика может сказать, — насколько гипотеза похожа на один конкретный человеческий вариант.

BLEU: что он на самом деле считает

Для $n = 1, 2, 3, 4$ берётся доля n -грамм гипотезы, нашедшихся в эталоне. Четыре доли усредняются **геометрически**, результат умножается на штраф за слишком короткий ответ. Смысла, грамматичности, синонимов и словоформ в этом определении нет.

эталон	гипотеза	BLEU
Не удалось подключиться к серверу	та же строка	1,000
Не удалось подключиться к серверу	Удалось подключиться к серверу	0,779
Сохранить изменения	Сохранение изменений	0,408

Противоположный смысл — 0,779, верный перевод другими формами — 0,408.
BLEU считает форму, а не смысл. Л.р. № 3, раздел 3.

chrF и почему для русского он подходит лучше

chrF сравнивает символьные n-граммы и считает F-меру — точность вместе с полнотой. У «сохранить» и «сохранение» общая основа, и словоизменение перестаёт обнулять совпадение.

	BLEU	chrF
другие формы	0,408	0,602
потеряно отрицание	0,779	0,919

Лучше — не значит безопасно. Потерянное отрицание chrF замечает ещё хуже BLEU: пропала одна короткая частица.

Ещё две метрики, о которых стоит знать: TER — сколько правок нужно постредактору; COMET — нейросеть, обученная на человеческих оценках.

→ **метрики машинного перевода** — BLEU и chrF одного сегмента, с учётом морфологии и без.

Слепые зоны: что метрика не поймает никогда

что случилось	пример из Л.р. № 3	BLEU
сломан плейсхолдер потеряно отрицание	s002: Удалить файл "(имя}"? — строка не соберётся «Удалось подключиться» вместо «Не удалось»	0,630 0,779
верный перевод	s065: «Приведенный ниже пример показывает...» вместо «В следующем примере показана...»	0,156

Медиана BLEU по корпусу — **0,366**. Приёмка по ней пропустила бы сломанную строку и отклонила безупречный перевод. Причина одна: метрики сравнивают форму, и инверсия смысла при минимальной правке формы для них невидима по построению. Это не дефект реализации.

Чем закрывают слепые зоны метрик

Раз метрика слепа по построению, её не чинят — её дополняют.

средство	на проверку	доля
BLEU ниже медианы	78	48,8 %
chrF ниже медианы	80	50,0 %
семантика $< 0,7$	15	9,4 %
формальные проверки	8	5,0 %

160 сегментов, Л.р. № 3, раздел 8.

Формальные проверки —
плейсхолдеры, числа, отрицание,
длина — ловят механическое, и
ловят полностью. Сломанный
плейсхолдер s002 нашли *только*
они: BLEU у него выше медианы,
семантическая близость — 0,801.

Средство ценно не полнотой, а отношением найденного к просмотренному. Порог по метрике отправляет на проверку половину корпуса.

Когда метрике можно верить

Можно

Сравнить две системы перевода на тысячах сегментов. Отследить, не ухудшилась ли модель после обновления. Отобрать сегменты, заведомо требующие внимания.

Нельзя

Принять или отклонить отдельный сегмент. Оценить качество на коротких строках интерфейса. Заменить метрикой приёмку человеком.

Вопрос заказчика из задания 9 Л.р. № 3: «можно ли принимать перевод, если BLEU выше порога?» Ответ — нет, и после этого блока вы можете объяснить почему, а не сослаться на интуицию. Это и есть профессиональная позиция, которую даёт курс.

БЛОК 5

Данные и разметка

Во что упирается качество, сколько стоит разметка и насколько ей можно верить. Это та часть работы, которую делает лингвист.


Во что упирается качество

Пять очевидных ходов и что они дают (Л.р. № 1, разделы 8, 9 и 13):

ход	результат	почему
подобрать гиперпараметры, 48 комбинаций	+0,000	нашлась ровно исходная
склеить слова и n-граммы	−0,019	больше признаков — больше шума
сменить модель	0,550–0,744	разброс 0,19
сменить предобработку	0,381–0,631	разброс 0,25
разметить больше , 20 Newsgroups	0,546 → 0,830	в 11 раз больше примеров

Порядок при нехватке качества: данные, потом признаки, потом модель. Донастройка даёт ноль, модель и признаки — величины одного порядка, данные — десятки процентов.

Кривая обучения читается и по горизонтали



Логистическая регрессия, пятикратная кросс-валидация.

Символьные n-граммы на **87** сегментах уже обгоняют слова, обученные на всех **128**. Удачная идея о признаках экономит 41 сегмент разметки.

Обе кривые на правом краю ещё растут: модель не насытилась данными.

→ **данные и разметка** — кривые считаются в браузере, модель переключается.

MQM: отраслевая схема оценки перевода

категория	что означает	пример
точность	смысл искажён, добавлен или потерян	пропало предложение
беглость	нарушены нормы языка перевода	сбой согласования
терминология	не тот термин, что принят в проекте	«любимые» вместо «избранное»
стиль	нарушен регистр или тон	«ты» вместо «вы»
разметка	сломаны плейсхолдеры, теги	{name} переведён

Серьёзность и вес: критическая — **25**, серьёзная — **5**, незначительная — **1**, нет — **0**.
Критическая — продукт сломан или смысл противоположный.

Веса неравномерны намеренно: одна критическая ошибка «стоит» двадцати пяти незначительных. Они отражают стоимость последствий, а не частоту. Л.р. № 3, раздел 6.

Метрика против разметки

Десять сегментов, размеченных в разделе 6 Л.р. № 3

сегмент	ошибка	BLEU
s002	критическая, разметка	0,630
s006	незначительная, термин	0,630
s012	критическая, разметка	0,347
s115	критическая, точность	0,170
s065	нет	0,156

Пять из десяти; остальные — в playground'е.

Критическая и незначительная ошибки получили *одинаковый* BLEU. Безупречный перевод — самый низкий из десяти.

Ранговая корреляция BLEU и штрафа MQM — +0,18: связи нет ни в какую сторону. Порога BLEU, при котором приёмка на этих десяти сегментах не ошибается, не существует.

→ **данные и разметка** — порог приёмки движется ползунком, ошибки считаются сразу.

Согласие разметчиков

Разметка — это измерение, и у измерения есть надёжность. Если два человека размечают один материал по-разному, ненадёжна и разметка, и всё, что из неё выведено.

Каппа Коэна — согласие за вычетом случайного:

$$\kappa = \frac{p_{\text{совп}} - p_{\text{случ}}}{1 - p_{\text{случ}}}$$

Пример Л.р. № 3: совпали 8 ответов из 10, случайно совпало бы 22 %, $\kappa = 0,744$ — «существенное» согласие.

Расхождения примера — s003: точность или терминология? s006: терминология или стиль? Оба ответа защитимы, пока руководство для разметчиков не решило иначе. Написать его — профессиональная задача (Л.р. № 3, задание 8).

Зачем вычитать случай. Если 80 % сегментов без ошибок, два разметчика, которые вообще не согласны, совпадут в **65 %** случаев — просто потому, что оба чаще ставят «нет». Каппа у них — ноль.

Права, персональные данные и загрязнение корпусов

Права на корпус

Тексты из интернета не становятся свободными оттого, что доступны. У OPUS, Universal Dependencies и подобных ресурсов лицензии указаны явно — их надо читать.

Персональные данные

Переписка, тикеты поддержки и отзывы содержат имена, адреса, номера. Обезличивание — обязательный этап, а не пожелание.

Следы машинного перевода

Заметная часть параллельных корпусов из сети сама получена машинным переводом. Модель воспроизводит чужие ошибки, а оценка на таких данных завышается.

Умение сказать заказчику, что с корпусом что-то не так, — часть профессии, и её не заменит никакая метрика.

Что связывает все пять блоков

Машинное обучение не работает с языком — оно работает с числами, полученными из языка. Качество этого перехода определяет всё остальное.

Три вещи, которые делает лингвист и не может сделать инженер

Решает, что считать
единицей и как её
нормализовать.

блоки 1–2

Решает, что считать
ошибкой, и пишет об
этом руководство.

блоки 4–5

Читает результат и
объясняет, почему
модель ошиблась именно
так.

все лабораторные

Всё это измеримо, и в лабораторных вы измерите каждое.

Для желающих углубиться: D. Jurafsky, J. H. Martin. *Speech and Language Processing*, 3-е изд.,
свободно доступно онлайн.